

Memoire M1 - REN et entraînement de modèle sur données bruitées

Canonge Yeleen Fief Camille

Encadrants : Gaël Lejeune, Caroline Parfait, Ljudmila Petkovic

Semestre 2 M1 Langue et Informatique 2024-2025

Table des matières

1	Introduction	5
2	Contexte et état de l’art	9
2.1	Introduction de l’état de l’art	9
2.2	Pourquoi ce champ est important	10
2.3	Grands enjeux pour la REN identifiés dans les travaux existants	11
2.4	Méthodes de reconnaissance d’entités nommées sur données propres	12
2.5	Reconnaissance d’entités nommées sur données bruitées	14
3	Reconnaissance d’entités nommées sur textes OCR bruités : limites des modèles standards et enjeux méthodologiques	18
3.1	Limites des modèles standards sur les textes bruités	18
3.2	Évaluation et jeux de données pour la REN sur textes bruités	19
3.3	Périmètre de l’étude et ouvertures possibles	22
3.4	Contributions distinctives et choix méthodologiques	23
3.5	Synthèse critique de l’état de l’art	24
4	Données d’entraînement des modèles	26
4.1	Origine des données d’entraînement	26
4.2	Description du corpus et ses caractéristiques	27
5	Préparation des données et entraînement de modèles	31
5.1	Test du tuto	31
5.2	Détermination de l’accord majoritaire	32
5.2.1	Détermination de <i>Label_Maj</i> (étiquette majoritaire) .	32
5.2.2	Détermination de <i>Quaero_Maj</i> (catégorie fine)	33
5.2.3	Problèmes rencontrés	33
5.2.4	Conclusion de cette étape	33
5.3	Formatage des données	34
5.3.1	Formatage au format JSON	34

5.3.2	Encodage des données au format Spacy	38
5.4	Entraînement des modèles	40
5.5	REN à partir de nos modèles	41
6	Discussion et résultats	43
6.1	Comparaison du volume d'entités reconnues	43
6.2	Répartition des entités nommées par type	45
6.3	Évaluation des performances :	48
6.4	Impact du partitionnement des données d'entraînement	54
6.4.1	Modèle <i>enrichi</i>	54
6.4.2	Comparaison avec les autres modèles	56
6.5	Analyse des longueurs et de la similarité des entités	57
6.5.1	Analyse des longueurs des entités	57
6.5.2	Analyse de la similarité des entités	58
7	Conclusion générale	62
Annexes		64
Annexes		64
.1	Résultats détaillés du partitionnement des données d'entraînement pour les autres modèles	64
.1.1	Modèle initial	64
.1.2	Modèle enrichi <i>quaero</i> fusionné	66
.2	Précisions des mesures de similarité	70
.3	Retrouver tous nos codes et fichiers sur Github	71

Table des figures

3.1	Affichage de la sortie du modèle sur la plateforme GATE Cloud	19
6.1	Nombre total d’entités reconnues par modèle – version REF	43
6.2	Nombre total d’entités reconnues par modèle – version Tesseract	44
6.3	Nombre total d’entités reconnues par modèle – version Kraken	44
6.4	Répartition des entités nommées par modèle (OCR : TESSE- RACT)	46
6.5	Répartition des entités nommées par modèle (OCR : REF)	47
6.6	Répartition des entités nommées par modèle (OCR : KRAKEN)	47
6.7	Répartition des entités nommées par type sur le texte KRA- KEN – Modèle enrichi	54
6.8	Répartition des entités nommées par type sur les textes REF et TESSERACT – Modèle enrichi	55
6.9	Différence moyenne de longueur (en caractères) entre les enti- tés reconnues par nos modèles et celles de spaCy. Une valeur négative signifie que le modèle produit des entités plus courtes.	57
6.10	Comparaison des similarités textuelles moyennes calculées à partir de l’intersection des entités par position : Jaccard (en bleu) et Levenshtein (en orange).	59
6.11	Similarité moyenne (Cosine et Levenshtein) entre les entités reconnues par nos modèles et celles de spaCy, pour chaque OCR.	60
6.12	Distribution des similarités globales (Cosine à gauche, Leven- shtein à droite) selon les modèles, tous OCR confondus.	60
1	Répartition des entités par type – OCR KRAKEN – Modèle initial	64
2	Répartition des entités par type – OCR REF – Modèle initial	65
3	Répartition des entités par type – OCR TESSERACT – Mo- dèle initial	65
4	Répartition des entités par type – OCR KRAKEN – Modèle enrichi quaero fusioné	66

5	Répartition des entités par type – OCR REF – Modèle enrichi quaero fusioné	67
6	Répartition des entités par type – OCR TESSERACT – Mo- dèle enrichi quaero fusioné	68
7	Figures supplémentaires : similarité moyenne par OCR ou par modèle (Cosine et Levenshtein)	70

Chapitre 1

Introduction

La reconnaissance d’entités nommées (REN ou *Named-entity recognition*, *NER* en anglais), est une tâche fondamentale dans le champ du traitement automatique des langues (TAL). Elle consiste à identifier et à classier automatiquement des éléments textuels spécifiques tels que les noms de personnes, d’organisations, de lieux, de dates ou d’expressions numériques. Cette capacité à extraire des informations structurées à partir de textes non structurés est cruciale dans de nombreuses applications : analyse de documents, recherche d’information, traduction automatique, génération de résumés, ou encore compréhension de texte par des systèmes intelligents. Des standards plus complexes, comme ceux proposés par le projet QUAERO, permettent même de qualifier plus finement les entités en intégrant des informations sémantiques additionnelles (ex. type de lieu, rôle de l’entité, relations temporelles, etc.).

D’un point de vue historique, les premières approches de la REN étaient fondées sur des règles. Elles mobilisaient : des dictionnaires, des patrons linguistiques, et des expressions régulières pour repérer les entités dans les textes. Bien que performantes dans des contextes normés et bien contrôlés, ces méthodes ont rapidement montré leurs limites face aux variations inhérentes au langage naturel : lexicale, ambiguïté sémantique, formulations non standards, etc. Avec l’arrivée des méthodes d’apprentissage automatique (Machine Learning) la REN a connu une transformation profonde, grâce à des modèles capables d’apprendre des représentations linguistiques à partir de données annotées. Plus récemment, le Deep Learning a bouleversé les paradigmes de la REN en permettant d’atteindre des niveaux de précision inégalés grâce à des architectures neuronales complexes, notamment les réseaux de neurones récurrents (RNN), les Réseaux convolutionnels (CNN) et les modèles de type Transformer tels que BERT, ROBERTA ou XLM-R.

Cette évolution a été rendue possible, entre autres, par l’introduction

des plongements lexicaux (ou *word embeddings* en anglais) proposés par MIKOLOV et al., 2013. Ces représentations vectorielles continues des mots, telles que WORD2VEC, ont marqué une rupture majeure dans le traitement automatique des langues, en permettant de capturer des relations syntaxiques et sémantiques à partir de grandes quantités de textes non annotés. Contrairement aux représentations symboliques classiques, les plongements lexicaux encodent les similarités de sens dans des espaces multidimensionnels, facilitant ainsi l'apprentissage de modèles capables de généraliser au-delà des formes exactes rencontrées en entraînement. Cette avancée a ouvert la voie aux modèles neuronaux profonds et a constitué une étape fondamentale vers l'émergence des architectures contextuelles comme les TRANSFORMERS. Ces modèles, alimentés par de grandes quantités de données, exploitent les contextes linguistiques profonds et capturent des dépendances longues dans le texte, ce qui améliore considérablement la détection d'entités, même dans des contextes ambigus ou complexes. Le mécanisme d'attention introduit par les TRANSFORMERS permet notamment de pondérer l'importance des mots dans leur contexte, renforçant la précision des prédictions.

Dans ce cadre, la bibliothèque SPACY s'est imposée comme un outil de référence : open-source, rapide, et extensible, elle propose des modèles pré-entraînés pour différentes langues et différentes tâches de TAL, tout en permettant leur fine-tuning sur des corpus spécialisés. SPACY repose sur des algorithmes neuronaux performants qui peuvent être adaptés à des jeux de données spécifiques, notamment dans des contextes non standards, comme c'est le cas avec des textes bruités.

C'est précisément ce type de contexte que ce mémoire se propose d'étudier : l'entraînement et l'évaluation de modèles de REN sur des données bruitées. Par « données bruitées », on entend l'ajout, la substitution et la suppression de caractères dans des textes. Ces altérations ou contaminations HAMDİ et al., 2022 et KOUDORO-PARFAIT, 2025 sont dues à des erreurs de transcription par le système de reconnaissance optique de caractères (OCR), qui provoque des fautes typographiques, des conversions inexactes. Ces contaminations pourraient avoir comme origine des anomalies résultant de la numérisation de documents anciens ou dégradés, mais aussi d'erreurs propres aux systèmes d'OCR. Ces imperfections pourraient compliquer le traitement automatique du texte et affecter la qualité de l'annotation des entités nommées.

L'objectif principal de ce travail est de proposer une méthodologie pour entraîner des modèles de REN robustes capables de résister aux contaminations de l'OCR, tout en s'appuyant sur des corpus annotés issus de la littérature. Pour cela, nous combinons des annotations manuelles et automatiques, et nous explorons différentes stratégies d'adaptation, notamment via

le fine-tuning des modèles pré-entraînés sur SPACY.

Ce mémoire s’inscrit dans une démarche expérimentale et exploratoire visant à (i) étudier les limites actuelles des modèles de REN et à (ii) identifier des pistes concrètes pour améliorer leur robustesse face à des données bruitées. Les problématiques majeures identifiées sont les suivantes :

- 1. Limites des modèles pré-entraînés : Des outils comme SPACY, proposent des modèles sur l’étagère, calibrés sur des corpus standards. KOUDORO-PARFAIT, 2025 dans ses travaux démontre que lorsqu’ils sont confrontés à des textes contaminés les performances des modèles baissent du au fait qu’ils ne reconnaissent pas toutes les formes contaminées d’une même entités. Il apparaît intéressant d’explorer le fine-tuning ou l’entraînement complémentaire sur des corpus bruités pour améliorer leurs performances dans ce contexte.
- 2. Formatage du *gold standard* pour l’entraînement : L’annotation de données bruitées est plus difficile que celle de textes standards. Elle demande une rigueur méthodologique pour éviter les incohérences.
- 3. Évaluation des performances et robustesse des modèles : Au-delà des métriques classiques (précision, rappel, F-mesure), il est crucial de mettre en place des protocoles d’évaluation qui permettent de cerner les faiblesses des modèles sur les entités mal identifiées. L’analyse qualitative des erreurs devient ici un levier pour comprendre comment et pourquoi le bruit affecte les prédictions.

Pour répondre à ces défis, notre méthodologie repose sur plusieurs axes. Premièrement, nous allons constituer un gold standard, c’est-à-dire un corpus annoté qui servira de vérité-terrain pour l’évaluation, nous annotons les versions originales et les versions bruitées des textes, notamment les sorties OCR issues de différents systèmes : KRAKEN et TESSERACT. Deuxièmement, nous allons adapter un modèle SPACY à ces données, en expérimentant différentes méthodes d’apprentissage supervisé ou semi-supervisé. Troisièmement, nous proposerons un protocole d’évaluation rigoureux pour mesurer la performance des modèles entraînés sur des données bruitées, en comparant des configurations d’entraînement standard et adaptées, pour déterminer si les modèles adaptés aux données bruitées sont plus performant que le modèle sur l’étagère.

En résumé, ce mémoire vise à contribuer à la compréhension des enjeux liés à l’apprentissage de la reconnaissance d’entités nommées en conditions réelles, là où les données sont rarement idéales. Les résultats attendus pourraient avoir des retombées concrètes pour toutes les applications du TAL reposant sur des documents historiques, des archives numérisées, ou des textes produits dans des conditions techniques imparfaites. En explorant les interactions entre bruit textuel, annotation, entraînement de modèles et évaluation,

nous espérons proposer des solutions concrètes et transférables pour améliorer la robustesse des systèmes de REN modernes.

Chapitre 2

Contexte et état de l’art

2.1 Introduction de l’état de l’art

La reconnaissance d’entités nommées (Named Entity Recognition, ou REN) constitue une tâche centrale dans le domaine du traitement automatique des langues (TAL), en particulier pour l’extraction d’informations structurées à partir de textes non structurés. Cette tâche, qui consiste à détecter et classer les entités (personnes, lieux, organisations, etc.) dans un texte, est bien maîtrisée dans des contextes où les données sont propres et bien formées. Toutefois, son application à des corpus bruités, comme ceux issus de la reconnaissance optique de caractères (OCR), reste un défi majeur.

Ce problème est particulièrement saillant dans le contexte des humanités numériques, où l’on cherche à valoriser des corpus patrimoniaux numérisés, tels que ceux produits par le projet européen ELTeC (European Literary Text Collection). Ces corpus, composés de textes littéraires du XIXe siècle, sont souvent disponibles sous forme de transcriptions OCR, dont la qualité varie considérablement. Les erreurs typiques de l’OCR (substitutions de caractères, fautes d’orthographe, segmentation incorrecte) nuisent directement à la qualité des analyses automatiques, notamment à la reconnaissance correcte des entités nommées. Dans ce contexte, il devient impératif d’évaluer et d’adapter les modèles de NER aux spécificités de ces textes bruités.

Plusieurs études ont déjà mis en évidence les limites des systèmes de NER classiques lorsqu’ils sont appliqués à de tels corpus. LAMPLE et al., 2016, DEVLIN et al., 2019 ou encore PETERS et al., 2018 ont proposé des architectures performantes sur des jeux de données standard (CoNLL, OntoNotes), mais leur robustesse diminue sensiblement lorsqu’ils sont confrontés à des textes présentant des erreurs d’OCR. Ce constat est confirmé dans des travaux plus récents spécifiquement dédiés à cette problématique. Par

exemple, la thèse de KOUDORO-PARFAIT, 2025 explore en profondeur la reconnaissance d’entités spatiales dans des textes littéraires OCRisés du corpus ELTeC, en s’intéressant notamment à la désambiguïsation morphologique des entités nommées. Caroline Koudoro-Parfait a également montré que même les meilleurs systèmes de REN actuels perdaient en précision et en rappel sur des textes OCRisés, malgré des performances satisfaisantes sur leur version « propre ».

Dans ce contexte, notre travail s’inscrit dans une démarche appliquée et pragmatique. Nous avons choisi d’entraîner un modèle de REN à l’aide de l’outil SpaCy, sur un sous-ensemble annoté manuellement de textes OCRisés issus du corpus ELTeC (notamment *Carraud* et *Daudet*). L’objectif est double : d’une part, mesurer empiriquement la robustesse du modèle entraîné à partir de données bruitées ; d’autre part, proposer une méthodologie reproductible, légère et adaptée aux réalités des corpus patrimoniaux littéraires. Ce mémoire s’attache donc à explorer, dans un premier temps, les approches existantes (sur données propres comme sur données bruitées), avant de situer notre propre contribution dans ce paysage scientifique.

2.2 Pourquoi ce champ est important

La reconnaissance d’entités nommées (REN) joue un rôle essentiel dans de nombreuses applications en traitement automatique des langues, allant de la recherche d’information à la fouille de texte, en passant par les systèmes de question-réponse, les assistants numériques ou encore la modélisation des réseaux de personnages en littérature. L’intérêt de cette tâche réside dans sa capacité à transformer des textes non structurés en données structurées, exploitables par des systèmes informatiques ou des chercheurs en sciences humaines.

Dans le cadre des humanités numériques, la REN ouvre des perspectives inédites d’analyse pour les corpus patrimoniaux. Ces textes, souvent anciens, permettent d’interroger des représentations sociales, des réseaux culturels, ou des dynamiques spatiales historiques. Or, ces corpus, comme ceux proposés par le projet ELTeC, sont fréquemment disponibles sous forme de transcriptions OCR, avec un niveau de bruit non négligeable. La REN appliquée à ces documents permettrait par exemple de cartographier automatiquement les lieux cités dans les œuvres littéraires du XIXe siècle, ou d’analyser la diversité des noms de personnes mentionnés dans différents genres ou mouvements littéraires.

Plus largement, ce champ est d’autant plus important que la problématique de la robustesse des modèles de REN aux conditions réelles d’usage

(données bruitées, erreurs de transcription, orthographes anciennes) reste un défi technologique majeur. Les travaux de MAYHEW et al., 2019 ou encore de RIJHWANI et NEUBIG, 2020 insistent sur la nécessité de concevoir des modèles capables de s’adapter aux variations linguistiques, aux erreurs systématiques de l’OCR et aux corpus peu standardisés.

Dans ce contexte, la question de la fiabilité des résultats produits par les systèmes de REN sur des données issues d’un pipeline d’OCR est cruciale pour garantir des analyses scientifiques pertinentes. Elle touche non seulement la performance brute des modèles, mais aussi leur applicabilité dans des projets de recherche interdisciplinaires, où la reproductibilité, la transparence méthodologique et la gestion de l’erreur sont au cœur des attentes scientifiques.

2.3 Grands enjeux pour la REN identifiés dans les travaux existants

À travers les différentes études récentes portant sur la reconnaissance d’entités nommées, plusieurs enjeux méthodologiques, techniques et épistémologiques émergent. Ces défis sont particulièrement visibles dans les travaux portant sur des corpus bruités ou patrimoniaux, comme ceux que nous avons nous-mêmes mobilisés dans cette recherche.

Un premier enjeu transversal est celui de la robustesse des modèles face au bruit, en particulier aux erreurs induites par l’OCR. Les travaux de KOUDORO-PARFAIT et al., 2022 et RIJHWANI et NEUBIG, 2020 insistent sur la dégradation importante des performances des modèles de REN lorsqu’ils sont appliqués à des textes contenant des erreurs typographiques, des fautes de segmentation ou des formes anciennes. Ce constat est partagé par MAYHEW et al., 2019, qui proposent un entraînement spécifique sur données bruitées, afin de renforcer la résilience des modèles.

Un second enjeu récurrent est celui de l’adaptation des jeux de données et des protocoles d’évaluation. Dans la plupart des études, les performances sont mesurées sur des corpus standardisés et bien annotés (comme CoNLL ou OntoNotes), ce qui limite la validité des résultats dans des contextes plus réalistes. Plusieurs chercheurs, notamment BELTAGY et al., 2019, proposent des corpus ou modèles spécialisés (dans les domaines scientifique ou bruité) pour améliorer la correspondance entre entraînement et utilisation réelle. De manière similaire, MERDJANOVSKA et al., 2024 montrent que la qualité et la cohérence des annotations, notamment en présence de bruit réel introduit par des erreurs humaines, ont un impact décisif sur les performances des

systèmes de NER. Leur benchmark NoiseBench permet de mieux quantifier cet effet et d’orienter l’entraînement vers des modèles plus robustes.

Troisième enjeu soulevé par KOUDORO-PARFAIT, 2025 : la difficulté de traiter des entités non standardisées dans les textes littéraires. La variabilité lexicale, les références obliques et les entités fragmentées compliquent l’étiquetage automatique. Cela conduit à explorer des approches hybrides, combinant des méthodes statistiques (ou neuronales) avec des ressources externes ou des règles linguistiques.

Enfin, un quatrième enjeu porte sur la reproductibilité et la transférabilité des résultats. Peu d’études fournissent des pipelines complets facilement adaptables à d’autres corpus. Des initiatives comme celles de MARTIN, MULLER et al., 2020 ouvrent cependant la voie à des modèles open-source, multilingues et réentraînables.

Ces enjeux forment le socle des orientations récentes en REN appliquée à des données bruitées, et justifient la mise en place d’approches localisées, simples à déployer et centrées sur l’adaptation aux contraintes du corpus, comme celle que nous avons menée dans ce mémoire.

2.4 Méthodes de reconnaissance d’entités nommées sur données propres

Une grande partie des avancées en reconnaissance d’entités nommées (REN) repose sur des expériences menées sur des corpus dits « propres », c’est-à-dire exempts de bruit typographique ou sémantique, et généralement bien annotés. Ces corpus incluent typiquement CoNLL-2003 TJONG KIM SANG et DE MEULDER, 2003, OntoNotes WEISCHEDEL et al., 2013, ou encore WNUT DERCZYNSKI et al., 2017. Les études sur ces données ont permis de structurer l’évolution des architectures utilisées et de poser des bases solides pour les tâches de REN.

Tout d’abord, les travaux de LAMPLE et al., 2016 ont introduit l’usage de réseaux neuronaux récurrents (BiLSTM) couplés à des CRF (Conditional Random Fields), en exploitant des embeddings de mots et de caractères. Leur modèle a constitué une avancée importante, permettant de capturer à la fois les dépendances contextuelles et la structure séquentielle des entités.

Par la suite, DEVLIN et al., 2019 ont proposé BERT (Bidirectional Encoder Representations from Transformers), qui a marqué une rupture en modélisant le contexte de manière bidirectionnelle sur des millions de phrases. Leurs résultats sur les corpus standards de REN ont surpassé les approches précédentes, montrant qu’un pré-entraînement massif pouvait offrir une ro-

bustesse accrue, même avec peu d'exemples annotés.

En contexte francophone, MARTIN, MULLER et al., 2020 ont adapté cette logique avec CamemBERT, un modèle préentraîné sur un large corpus français. Ils montrent que CamemBERT, lorsqu'il est fine-tuné sur des données REN françaises (notamment WikiNER), atteint des performances comparables aux meilleurs systèmes anglophones.

Ces travaux posent les fondements techniques de notre approche. Cependant, leurs résultats reposent sur l'hypothèse d'une langue standardisée et de documents sans bruit, ce qui ne reflète pas les contraintes des textes littéraires patrimoniaux, ni les erreurs générées par des procédés OCR.

Ainsi, bien que ces architectures soient largement éprouvées, elles nécessitent des adaptations spécifiques pour être transposées efficacement sur des textes bruités comme ceux du corpus ELTeC utilisé dans notre étude.

En parallèle des approches traditionnelles centrées sur l'amélioration des architectures de modèles ou la correction explicite des données bruitées, certaines études récentes explorent des techniques d'augmentation de données visant à renforcer la robustesse des systèmes de reconnaissance d'entités nommées (REN). Ces approches se distinguent par leur capacité à introduire des signaux contextuels supplémentaires, soit à travers des données externes, soit par des mécanismes de généralisation inductive.

Dans cette perspective, AI et al., 2024 proposent une méthode originale baptisée *retrieval-based augmentation*, spécifiquement conçue pour les scénarios où les données d'entrée sont bruitées, notamment à la suite d'un traitement OCR. Leur hypothèse de départ repose sur le constat que les erreurs introduites par l'OCR peuvent altérer des indices lexicaux cruciaux pour la détection d'entités, en particulier les noms propres, les noms composés ou les entités rares. Pour compenser cette perte d'information, ils exploitent un corpus externe de documents propres — structurés et indexés — afin de récupérer, pour chaque passage bruité, des exemples textuels similaires qui servent à enrichir le contexte sémantique du modèle.

Le mécanisme d'augmentation repose sur une double étape : (1) extraction d'un vecteur de requête à partir du texte bruité via un encodeur BERT, puis (2) recherche vectorielle dans un index dense pour récupérer les passages les plus proches. Ces passages sont ensuite concaténés ou intégrés via un encodeur croisé dans l'architecture de REN, apportant un contexte paraphrastique ou sémantique susceptible de compenser les distorsions OCR. L'évaluation menée sur des corpus bruités artificiellement et réels montre une nette amélioration des scores F1, en particulier pour les entités longues ou peu fréquentes.

L'un des intérêts majeurs de cette approche est sa capacité à fonctionner

de manière complémentaire aux méthodes de correction ou de prétraitement. En effet, plutôt que de corriger explicitement les erreurs OCR, l’augmentation par récupération contourne le problème en ajoutant du contexte externe potentiellement plus fiable. Cette stratégie pourrait s’avérer particulièrement utile dans des contextes où la correction est risquée ou coûteuse, notamment sur des documents historiques fragiles ou mal scannés.

En lien avec notre propre étude, cette approche pose des jalons intéressants. Bien que notre corpus (Daudet, Carraud issus de ELTeC) ne bénéficie pas de bases de connaissances externes parfaitement alignées, l’idée d’enrichissement contextuel via des exemples similaires pourrait inspirer de futures expérimentations. Par ailleurs, le fait que leur méthode soit indépendante du domaine et applicable à différents types d’erreurs la rend particulièrement prometteuse dans le cadre de la REN sur textes OCRisés. Elle ouvre des perspectives vers l’intégration de contextes adjacents (chapitres voisins, textes d’un même auteur ou genre) comme sources de récupération interne.

2.5 Reconnaissance d’entités nommées sur données bruitées

Les travaux fondateurs de Koudoro-Parfait, 2025, dans le cadre d’une thèse dédiée à la REN sur textes issus d’OCR, soulignent que les modèles classiques de type BiLSTM-CRF ou BERT échouent systématiquement lorsqu’ils sont confrontés à des documents bruités, notamment issus de corpus littéraires patrimoniaux. Pour contourner cette limitation, Koudoro introduit une procédure d’injection de bruit simulé dans les données d’entraînement, reproduisant différentes classes d’erreurs OCR (substitution de lettres, suppressions, insertions, segmentation incorrecte, etc.). Elle observe que les modèles ainsi « préparés » aux anomalies typiques du traitement OCR gagnent en robustesse, atteignant des F1-scores supérieurs de 15 à 20 points par rapport aux modèles naïfs sur des textes OCRisés du XIX^e siècle.

Dans une approche proche, RIJHWANI et NEUBIG, 2020 se concentrent sur la robustesse des modèles de REN face à des erreurs introduites artificiellement. Ils développent un pipeline d’augmentation de données simulant des erreurs fréquentes dans des tweets ou documents historiques, et appliquent cette technique à des modèles BERT. Leur contribution majeure réside dans la comparaison systématique entre types de bruit (phonétique, visuel, typo) et leur impact sur la performance. Ils démontrent qu’une stratégie de bruit ciblé améliore la généralisation sur des jeux de données inconnus, tout en préservant les performances sur textes propres.

Les expériences de MAYHEW et al., 2019 confirment ces constats. Ils montrent que les modèles traditionnels sont particulièrement sensibles à de petites modifications orthographiques, souvent invisibles pour un lecteur humain. Leur contribution repose sur l’introduction d’un modèle d’attention résistant au bruit, couplé à des embeddings contextuels renforcés. Grâce à des tests sur des versions dégradées du corpus CoNLL-2003, ils obtiennent des gains significatifs en robustesse. Ils insistent aussi sur l’importance de disposer de benchmarks bruités, soulignant un manque dans la littérature à cette époque.

Dans le champ spécifique des textes historiques, MONCLA et ZEGHIDI, 2025 insistent sur les défis posés par la reconnaissance d’entités nommées dans des documents du XVIII^e siècle, notamment en raison des entités imbriquées et des variations orthographiques. Leur étude met en lumière la nécessité d’utiliser des représentations fines au niveau des tokens et des spans, avec des modèles basés sur les transformateurs (comme CamemBERT), qui permettent de capturer la complexité morphologique et lexicale des textes anciens. Cette approche montre une grande efficacité même dans des contextes fortement altérés ou peu annotés.

Enfin, KOUDORO-PARFAIT et al., 2022 adopte un point de vue plus pragmatique, en développant une chaîne de traitement semi-automatique pour la REN sur documents OCR. Son approche combine une première phase de reconnaissance brute avec un modèle neuronal, suivie d’une interface d’annotation permettant la correction rapide par un annotateur humain. Cette boucle de rétroaction permet d’optimiser les performances tout en minimisant le coût d’annotation, en particulier dans des corpus très bruités comme les romans numérisés du XIX^e siècle. Ce type d’outil se révèle essentiel pour la constitution de jeux de données de qualité, ce que notre étude reprend partiellement à travers les annotations manuelles et les alignements avec les labels Quaero.

Ce panorama met en évidence plusieurs points de convergence entre les approches :

- La majorité des études insistent sur l’importance de **simuler ou annoter le bruit** dans les données d’entraînement, afin d’exposer les modèles aux erreurs qu’ils devront traiter.
- L’intégration d’unités sous-lexicales (caractères, morphèmes, n-grams) est **cruciale pour gérer l’orthographe non standard**, souvent présente dans les textes anciens ou OCRisés.
- Le recours à des architectures pré-entraînées type BERT, bien qu’efficace sur des textes modernes, **nécessite un fine-tuning spécifique** ou une adaptation structurelle pour résister au bruit.
- L’annotation manuelle ou semi-automatique reste indispensable pour

créer des corpus de référence adaptés aux contextes patrimoniaux.

Ces constats justifient notre propre méthodologie, qui repose sur l’annotation fine d’un corpus ELTeC bruité (Carraud et Daudet), le formatage en données de type SpaCy, et l’entraînement supervisé d’un modèle à partir de fichiers volontairement maintenus dans leur état OCR. L’objectif est de produire une reconnaissance robuste à la variabilité graphique et aux défauts structurels tout en s’appuyant sur les meilleures pratiques identifiées dans la littérature récente.

Au-delà de la robustesse des architectures, d’autres travaux se sont intéressés à des aspects plus structurels du traitement des données bruitées, notamment la dimension spatiale des entités, la correction automatique post-OCR, ainsi que la désambiguïsation contextuelle. Ces problématiques, moins explorées mais tout aussi fondamentales, sont particulièrement pertinentes pour les corpus historiques, souvent numérisés dans des conditions imparfaites.

KOUDORO-PARFAIT et al., 2022 proposent ainsi une approche de désambiguïsation morphologique automatique visant à améliorer la reconnaissance d’entités nommées sur des textes dégradés par OCR. Leur méthode repose sur une combinaison de techniques de normalisation lexicale et de désambiguïsation contextuelle. L’originalité de leur contribution réside dans l’exploitation fine des régularités morphosyntaxiques propres aux textes littéraires anciens. Cette stratégie permet non seulement d’améliorer la précision des entités reconnues, mais aussi de réduire les faux positifs générés par des formes lexicales ambiguës.

Dans une étude antérieure, KOUDORO-PARFAIT et al., 2021 concentrent leur analyse sur les entités spatiales, une catégorie particulièrement vulnérable au bruit OCR en raison de leur variabilité orthographique et morphologique. Leur étude repose sur l’évaluation comparative de plusieurs systèmes de REN appliqués à des textes OCRisés avec différents taux de dégradation. Ils concluent que la reconnaissance spatiale est significativement affectée par les erreurs OCR, notamment les confusions entre majuscules/minuscules et les segmentations erronées, entraînant des baisses de performance substantielles. Ce constat vient renforcer l’idée que certains types d’entités exigent des stratégies spécialisées.

Plus récemment, PETKOVIC et al., 2025 approfondissent la réflexion sur l’impact de la correction automatique de l’OCR sur la reconnaissance d’entités nommées dans des corpus littéraires bruités. Leur étude compare deux stratégies complémentaires : la correction des textes sources avant traitement, et le filtrage des entités en sortie. À partir de textes issus du projet ELTeC, ils montrent que les erreurs OCR peuvent nuire à la précision des systèmes, mais que certaines corrections, bien calibrées, peuvent aussi améliorer la stabilité

des prédictions.

Ces travaux mettent en évidence des points particulièrement convergents avec notre étude, en particulier dans leur utilisation de corpus historiques bruités similaires (textes issus du patrimoine littéraire), dans le choix des entités spatiales comme indicateurs de robustesse, ainsi que dans la prise en compte des erreurs de transcription comme facteur central. Ils permettent également de dégager deux orientations méthodologiques complémentaires : l'adaptation morpho-contextuelle en amont (désambiguïsation, nettoyage ciblé), et la robustesse par évaluation comparée des corrections automatiques. Notre propre démarche s'inscrit dans cette continuité, tout en apportant une nouveauté par l'usage de données annotées manuellement issues du corpus ELTeC (Daudet, Carraud), combinées à un entraînement supervisé sous spaCy sur données bruitées sans correction préalable systématique.

Chapitre 3

Reconnaissance d'entités nommées sur textes OCR bruités : limites des modèles standards et enjeux méthodologiques

3.1 Limites des modèles standards sur les textes bruités

Pour illustrer les difficultés que rencontrent les modèles standards de reconnaissance d'entités nommées (REN) sur des textes bruités, nous avons soumis un extrait du roman *Le Voleur* de Georges Darien (version OCR Tesseract) au modèle du French Named Entity Recognizer disponible sur la plateforme GATE Cloud¹.

1. <https://cloud.gate.ac.uk/shopfront/displayItem/french-named-entity-recognizer>




FIGURE 3.1 – Affichage de la sortie du modèle sur la plateforme GATE Cloud

Dans la figure ci-dessus, la présence d’entités géopolitiques évidentes comme **Belgique** et **France** ont bien été annotées, mais ce sont les 2 seules entités reconnues :

- **Belgique** (étiquette : LOC, type : pays)
- **France** (étiquette : LOC, type : pays)

Les autres entités potentielles, telles que des personnes ou des organisations mentionnées ailleurs dans le texte, ne sont pas reconnues, en partie à cause des erreurs d’OCR (*Mt.Randale* au lieu de *Mr.Randal* qui aurait dû être annoté comme *PER.*, *Ld Science* au lieu de *La Science* qui pourrait être annoté comme *MISC*, etc.).

Ces résultats motivent l’entraînement de modèles spécifiques capables de mieux gérer les textes dégradés, en adaptant l’encodage, les données d’apprentissage et les règles de reconnaissance.

3.2 Évaluation et jeux de données pour la REN sur textes bruités

L’évaluation des modèles de reconnaissance d’entités nommées (REN) repose traditionnellement sur des corpus annotés de haute qualité, tels que CoNLL-2003 ou OntoNotes. Toutefois, ces jeux de données, très propres et souvent homogènes, ne reflètent pas la réalité des textes bruités issus d’OCR ou de sources historiques. Plusieurs études récentes ont tenté de pallier ce manque en développant des protocoles d’évaluation plus représentatifs de ces contextes dégradés.

Les travaux de MAYHEW et al., 2019, déjà évoqués précédemment, ont introduit une version bruitée artificiellement du corpus CoNLL-2003, en si-

mulant des erreurs typographiques courantes. Ce corpus bruité permet de mesurer la robustesse des modèles de REN sans dépendre de jeux de données complexes à annoter manuellement. L’approche est méthodologiquement solide, mais reste limitée par le fait que le bruit introduit ne reflète pas toujours fidèlement les dégradations réelles, notamment celles liées à l’OCR ou à l’orthographe ancienne.

De son côté, KOUDORO-PARFAIT et al., 2022 propose une démarche complémentaire, en utilisant un corpus réel OCRisé (extraits de la Bibliothèque numérique Gallica) et en constituant un sous-ensemble annoté manuellement pour l’évaluation. Elle adopte un protocole à double échelle : une évaluation intrinsèque sur les données annotées, et une évaluation extrinsèque sur la capacité du modèle à détecter des entités dans des contextes non vus. Ce choix permet de mieux cerner la capacité de généralisation des modèles sur des textes non normalisés.

PETKOVIC et al., 2025 mettent en œuvre un processus semi-automatique d’annotation qui permet de réduire le coût du gold standard tout en assurant un bon niveau de qualité. Leur approche évalue l’efficacité de corrections en amont (texte OCR) ou en aval (sortie du système de REN), tout en soulignant le rôle central de l’annotation assistée dans le contexte patrimonial, où les ressources annotées sont rares et les textes souvent longs et hétérogènes.

Dans notre propre étude, le corpus utilisé provient du projet ELTeC (European Literary Text Collection) ELTEC, 2020, qui contient des œuvres littéraires européennes du XIX^e siècle numérisées à partir de scans OCR (notamment *Carraud* et *Daudet*). Contrairement aux approches précédemment citées, nous avons conservé les textes dans leur état brut OCRisé afin de maintenir l’environnement bruité, ce qui rend l’évaluation plus représentative des cas d’usage réels. Les entités ont été annotées manuellement par plusieurs annotateurs, durant une campagne d’annotation menée par Caroline Koudoro-Parfait durant sa thèse. Les annotateurs suivaient alors un guide d’annotation, et devaient également annoter les "LOC" selon un schéma d’annotations Quaero. La séparation entre jeux d’entraînement et de test a été assurée strictement par œuvre, garantissant l’absence de fuite de données.

L’évaluation de notre modèle suit un protocole standard (précision, rappel, F1-score), mais s’appuie également sur des analyses qualitatives d’erreurs, notamment dans les cas de d’entités partiellement déformés, de frontières mal segmentées ou de répétitions OCR. Ce double niveau d’analyse permet de mieux comprendre les faiblesses résiduelles du système, en lien direct avec la nature du bruit textuel.

En résumé, cet axe met en lumière la rareté de benchmarks adaptés à la REN sur textes bruités. Les stratégies adoptées par Koudoro, Lejeune ou Mayhew montrent la diversité des approches possibles (simulation, an-

notation partielle, semi-automatisation), mais aussi leurs limites respectives. Notre contribution se situe à l’intersection de ces pratiques, en combinant un corpus authentique, une annotation rigoureuse, et une évaluation orientée vers la robustesse sur données réelles.

Ces problématiques soulignent également l’importance cruciale du post-traitement OCR dans les phases d’évaluation et de déploiement des systèmes de reconnaissance d’entités nommées. Le bruit généré par l’OCR — erreurs de segmentation, substitutions de caractères, artefacts liés à la mise en page — peut entraîner une dégradation sévère des performances, en particulier dans les tâches sensibles à la précision lexicale comme la REN. C’est dans ce contexte que NGUYEN *et al.*, 2021 apportent une contribution majeure à travers une revue exhaustive des méthodes de post-traitement de l’OCR.

Leur synthèse, structurée autour de différentes catégories d’approches (règles linguistiques, modèles statistiques, réseaux neuronaux, et systèmes hybrides), propose un cadre analytique utile pour comprendre comment chaque méthode s’inscrit dans le pipeline de traitement linguistique. Les auteurs insistent sur le fait que le post-traitement ne constitue pas simplement une étape corrective, mais une phase fondatrice susceptible d’influencer toute la chaîne de traitement en aval, notamment la reconnaissance d’entités nommées, l’analyse syntaxique ou la classification de documents.

Nguyen *et al.* mettent en lumière plusieurs défis techniques récurrents : la difficulté à corriger automatiquement les erreurs sans introduire de nouvelles ambiguïtés, l’absence de normes unifiées pour représenter les versions pré- et post-corrigées d’un texte, et la variabilité de performance selon le type de corpus. Leur méta-analyse sur les corpus historiques et littéraires montre par exemple que les modèles de correction supervisés entraînés sur des textes modernes perdent en efficacité face à des styles anciens ou régionaux. Par conséquent, ils recommandent d’adopter des stratégies de correction localisées, couplées à des modèles adaptatifs, c’est-à-dire des systèmes capables d’ajuster leur comportement aux spécificités linguistiques du corpus cible via des techniques d’adaptation de domaine.

L’un des apports centraux de cette étude réside dans la mise en corrélation explicite entre la qualité du post-OCR et les métriques de performance en TALN. Ils démontrent que des améliorations même marginales dans la correction OCR peuvent induire des hausses substantielles de scores F1 dans des systèmes de REN, notamment pour les entités longues ou multi-mots. Ce constat conforte l’idée que la préservation ou la restauration des indices orthographiques est essentielle à la performance des modèles.

Dans notre propre cadre expérimental, cette perspective s’avère particulièrement pertinente. Travaillant sur des textes du corpus ELTeC (Daudet, Carraud), fortement sujets aux erreurs OCR, nous avons délibérément choisi

de ne pas recourir à une correction systématique automatisée, afin d'évaluer la résilience intrinsèque du modèle entraîné sur des données bruitées. L'approche de Nguyen *et al.* permet néanmoins de situer cette décision méthodologique dans un cadre plus large : celui d'une tension entre robustesse modèle et correction en amont. À terme, leur travail offre un réservoir de techniques potentielles pour intégrer, dans une phase ultérieure, un post-traitement adaptatif ciblant les entités nommées, tout en respectant la nature historique et patrimoniale du corpus.

3.3 Périmètre de l'étude et ouvertures possibles

Malgré la diversité des approches explorées pour la reconnaissance d'entités nommées (REN) sur des données bruitées, plusieurs lacunes demeurent dans les travaux existants. Ces manques concernent à la fois la nature des données utilisées, les objectifs méthodologiques poursuivis, et les types d'entités considérés. Notre étude se positionne précisément dans ces angles morts, en apportant une contribution ciblée sur des corpus peu traités, avec une granularité d'analyse rarement abordée.

Tout d'abord, la majorité des études sur la REN bruitée utilisent des corpus où le bruit est artificiellement injecté. C'est le cas notamment chez Mayhew *et al.* MAYHEW et al., 2019, qui génèrent des erreurs de type OCR de manière contrôlée pour entraîner ou tester des modèles. Bien que ces travaux soient utiles pour comprendre les effets du bruit sur la performance, ils ne capturent pas fidèlement la complexité réelle des erreurs issues d'une numérisation patrimoniale. En revanche, notre corpus — constitué d'extraits du ELTeC (European Literary Text Collection), incluant des textes de Daudet et Carraud — contient des erreurs OCR authentiques, non corrigées, issues de documents historiques scannés. Ce choix permet de tester la robustesse du modèle dans un contexte réaliste, mais aussi historiquement pertinent.

Sur le plan des entités traitées, les études se focalisent majoritairement sur des entités classiques (personnes, lieux, organisations). Or, dans un contexte littéraire, les entités peuvent inclure des notions plus complexes comme des figures historiques, des toponymes archaïques, ou des constructions littéraires ambiguës. Peu d'études, à l'exception notable de KOUDORO-PARFAIT et al., 2021, ont étudié la reconnaissance d'entités spatiales dans des textes OCR bruités littéraires. Mais même ces dernières se concentrent sur des contextes multilingues génériques, sans explorer des combinaisons fines comme l'entraînement mono-langue et le test croisé sur d'autres textes du même corpus.

En ce qui concerne les outils, les pipelines utilisés sont généralement conçus pour des données propres. SpaCy, par exemple, est peu documenté

dans des contextes de données bruitées. À notre connaissance, aucune étude n’a encore documenté l’entraînement d’un modèle SpaCy entièrement supervisé sur un corpus OCR bruité francophone, avec un jeu d’annotations Quaero et une segmentation manuelle. La plupart des travaux optent pour des frameworks plus complexes comme Flair, BERT ou Stanza, qui nécessitent un pré-entraînement massif. Notre choix de SpaCy repose sur sa légèreté, sa reproductibilité, et sa modularité, qui en font un candidat pertinent pour des contextes de numérisation patrimoniale.

Enfin, très peu de recherches proposent une évaluation croisée sur différents sous-corpus d’un même ensemble littéraire. Dans notre étude, nous entraînons un modèle sur certains textes du corpus ELTeC, puis nous évaluons sur d’autres textes du même ensemble non vus pendant l’entraînement. Cette stratégie permet de tester la généralisation sur des styles proches mais non identiques, ce qui est rarement abordé dans la littérature existante.

En somme, les recherches actuelles abordent partiellement la problématique de la REN sur données OCR bruitées, mais laissent de côté des dimensions essentielles liées à la nature historique, littéraire et francophone des corpus. Notre travail se propose de combler ces vides en adoptant une approche méthodologique fine et reproductible.

3.4 Contributions distinctives et choix méthodologiques

Notre étude se distingue des travaux précédemment analysés sur plusieurs aspects méthodologiques et empiriques, que nous avons spécifiquement conçus pour répondre aux défis posés par la reconnaissance d’entités nommées (REN) dans des textes littéraires OCR bruités. Contrairement aux approches généralistes ou artificielles, notre protocole s’appuie sur des données réelles, des annotations manuelles rigoureuses et une architecture légère mais robuste.

Premièrement, alors que la plupart des études utilisent des jeux de données artificiellement bruités MAYHEW et al., 2019, nous avons choisi de travailler exclusivement avec des documents issus du corpus ELTeC — collection multilingue de textes littéraires du XIX^e siècle — contenant des erreurs OCR naturelles, telles qu’obtenues après numérisation. Cette décision permet d’évaluer la performance d’un système de REN dans un cadre réaliste, avec des erreurs de segmentation, des substitutions de caractères, ou encore des déformations typographiques qu’on ne retrouve pas dans les jeux simulés.

Deuxièmement, nous réutilisons une annotation manuelle fine sur des ex-

traits choisis (Carraud et Daudet), en combinant deux types de labels : les annotations PER, LOC, ORG et MISC, puis l'étiquette LOC est précisée grâce aux annotations Quaero, largement référencées dans les travaux de KOUDORO-PARFAIT, 2025.

Troisièmement, nous avons choisi un outil d'entraînement relativement peu exploité dans ce contexte : la bibliothèque SpaCy. La majorité des études utilisent des architectures lourdes basées sur BERT RIJHWANI et NEUBIG, 2020, ou des modèles spécialisés. Or, SpaCy offre une combinaison intéressante de légèreté, de rapidité et de personnalisation, ce qui en fait un candidat idéal pour des corpus réduits, peu normalisés, ou multilingues. À notre connaissance, aucune étude n'a documenté l'entraînement d'un modèle SpaCy de REN sur corpus littéraire OCR bruité français, avec une évaluation croisée intra-corpus.

Quatrièmement, notre méthodologie inclut un formatage précis des données d'apprentissage, en structurant chaque phrase avec ses entités annotées dans un fichier CSV, puis en les encryptant avec les outils fournis par SpaCy. Ce protocole garantit la reproductibilité et la clarté des étapes. L'évaluation a été menée sur des textes tenus hors du jeu d'entraînement, mais appartenant au même corpus (autres extraits de l'ELTeC), afin d'évaluer la capacité du modèle à généraliser sans recourir à un transfert inter-corpus, comme c'est souvent le cas dans la littérature NGUYEN et al., 2021.

Enfin, notre démarche se situe à l'intersection de plusieurs approches complémentaires. Elle reprend les préoccupations morphologiques et spatiales de KOUDORO-PARFAIT et al., 2021, 2022, tout en intégrant des choix techniques centrés sur la reproductibilité, la modularité et la précision manuelle. L'utilisation conjointe de Quaero et d'un label "maj" enrichit la granularité des analyses, et permet de faire émerger des types d'erreurs peu traités dans les travaux précédents, notamment les entités partiellement corrompues ou ambiguës dans des contextes narratifs.

En somme, notre approche combine rigueur annotative, légèreté technique et réalisme des données, dans un cadre encore largement sous-exploré par la littérature actuelle.

3.5 Synthèse critique de l'état de l'art

À l'issue de cette revue critique de la littérature, plusieurs constats s'imposent. Les recherches sur la reconnaissance d'entités nommées (REN) ont

largement progressé au cours de la dernière décennie, tant sur données propres que sur données bruitées. Toutefois, les approches existantes tendent à privilégier soit des corpus contemporains, soit des environnements de test artificiels où le bruit est injecté de manière contrôlée.

Peu de travaux se sont intéressés à la REN sur des textes OCR historiques, en particulier littéraires, où les erreurs sont structurellement plus complexes et les entités souvent ambiguës. Certaines études pionnières — comme celles de KOUDORO-PARFAIT et al., 2021 ou RIJHWANI et NEUBIG, 2020 — ont mis en évidence les effets du bruit sur la performance des modèles, mais sans explorer en profondeur le cas du français littéraire patrimonial.

L'état de l'art montre également que la question de l'évaluation croisée intra-corpus, la granularité des labels annotés, ou encore l'usage d'outils légers comme SpaCy, sont encore très peu documentés. De plus, l'articulation entre prétraitement OCR et apprentissage supervisé reste un champ ouvert, notamment dans une perspective d'applicabilité sur de petits corpus hétérogènes.

Notre étude s'inscrit ainsi dans un cadre méthodologique original, à la fois ancré dans les limites identifiées et en rupture avec les pratiques dominantes. Elle vise à proposer une approche reproductible, légère et adaptée aux réalités du traitement de textes patrimoniaux OCR bruités, en combinant annotation fine, choix outillique pragmatique et évaluation croisée rigoureuse. Cette orientation méthodologique sera explicitée dans la section suivante.

Chapitre 4

Données d’entraînement des modèles

4.1 Origine des données d’entraînement

Les données que nous utilisons dans ce mémoire proviennent de la *European Literary text Collection* ELTeC ELTEC, 2020, un corpus développé pour l’analyse des textes littéraires européens du XIXe siècle, numérisé et transcrits automatiquement. Le projet ELTeC vise à fournir une ressource riche et variée pour les chercheurs en TAL et en linguistique computationnelle, en proposant des oeuvres littéraires dans plusieurs langues européennes. Ces textes ont été transcrits à l’aide de la reconnaissance optique de caractères (OCR), une technologie permettant de convertir des documents imprimés ou manuscrits en texte numérique. Cependant cette procédure n’est pas sans défaut : les systèmes OCR peuvent générer des erreurs de transcription qui dégradent la qualité des données, particulièrement dans des textes anciens où la typographie et l’état de conservation des documents peuvent poser problème.

La reconnaissance optique de caractères (OCR) fonctionne en analysant des images de texte et en identifiant les caractères et mots présents, afin de les convertir en un format numérique. Toutefois les erreurs courantes dans les transcriptions OCR incluent des substitutions de caractères, des omissions de mots ou des erreurs de ponctuation, notamment lorsque les documents sont anciens et difficiles à lire. Ces erreurs affectent directement la qualité des annotations, en particulier pour la reconnaissance d’entités nommées, car elles rendent l’identification des entités plus difficile pour les modèles de TAL.

Le corpus que nous exploitons ici a déjà été utilisé dans des travaux de

recherche antérieurs, notamment par KOUDORO-PARFAIT et al., 2022, qui se sont intéressés à l’impact du bruit OCR sur la reconnaissance d’entités nommées. Notre objectif d’étude étant d’évaluer l’impact du bruit et d’essayer de le réduire lors de la reconnaissance d’entité nommées, le fait que nos données soient des textes anciens où les caractères typographiques sont souvent difficiles à interpréter par les systèmes OCR modernes est une influence de plus à prendre en compte.

4.2 Description du corpus et ses caractéristiques

Le corpus utilisé dans cette recherche est composé de deux textes littéraire du XIXème siècle, choisis pour leur diversité linguistique et culturelle. Il y en dans un premier temps un texte dont l’auteur est CARRAUD, le texte s’intitule "*Petite Jeanne*" et pour le second texte il provient lui de l’auteur DAUDET, il s’intitule "*Petite Chose*". Dans notre corpus, il y a 3 versions de chaque texte, voici une description des différentes versions présentes :

- **Version de référence non bruitée :** Cette version correspond à une transcription manuelle du texte, soigneusement vérifiée pour garantir sa fidélité par rapport à l’original. Elle sert de base de comparaison pour évaluer l’impact des erreurs de transcription générées par les outils OCR.
- **Version bruitée avec deux OCR différents :** Ces deux autres versions de chaque texte ont été produites à l’aide de différents OCR, un par Kraken base et l’autre par Tesseract. Chaque outil présente des caractéristiques uniques en termes de précision et de gestion des erreurs. Kraken est particulièrement adapté à la reconnaissance de textes écrits avec des polices anciennes, tandis que Tesseract qui est un outil OCR open-source, est souvent utilisé pour des textes plus récents. Les erreurs résultant de ces outils varient, cela inclut des substitutions de caractères, des pauvaises séparations de mots ou des erreurs de ponctuation, cela rend ces deux versions des textes plus difficiles à analyser.

Dans notre corpus, toutes les versions des deux textes ont subis plusieurs annotations, tout d’abord une annotation à l’aide de la REN de Spacy, puis par la suite une annotation manuelle par sept annotateurs pour le texte de CARRAUD et six pour le texte de DAUDET. Les annotateurs ont suivi des critères définis par Caroline Koudoro-Parfait afin d’avoir des annotations cohérentes. Par conséquent nous avons obtenu pour chaque annotateur sept et six fichiers au format csv qui regroupaient dans une première co-

bonne les tokens, dans une second colonne les annotations faites par Spacy et dans les colonnes suivantes les annotations faites par les annotateurs. Si l’annotateur était en accord avec l’annotations Spacy alors il ne mettait rien, si il n’était pas d’accord alors il mettait son annotation dans la dernière colonne, pour certaines annotations de type LOC, celles-ci avaient une colonne supplémentaire afin de rajouter une annotation Quaero. Ces différentes consignes permettent de mesurer la qualité et la cohérence des annotations dans un contexte où des erreurs OCR peuvent influencer la REN. Puisque nous avons plusieurs annotateurs, nous pouvons également mesure l’accord inter-annotateurs qui nous donne des informations supplémentaires sur l’impact des erreurs OCR.

Métrique	CARRAUD			DAUDET		
	REF	Kraken	Tessfr	REF	Kraken	Tessfr
Total tokens	6500	6500	6500	6500	6500	6500
Tokens annotés	384	374	376	259	260	237
PER	356	352	358	198	202	188
LOC	13	10	5	38	38	34
MISC	15	12	13	23	19	14

TABLE 4.1 – Statistiques de tokens annotés pour les textes CARRAUD et DAUDET selon les versions

Le tableau présente les statistiques d’annotation des entités nommées pour deux textes littéraires, CARRAUD et DAUDET, chacun traité selon trois versions issues de systèmes OCR ou de référence : REF (référence manuelle ou gold standard), Kraken et Tessfr (Tesseract français). Pour chaque version, plusieurs métriques sont fournies, notamment le nombre total de tokens, le nombre de tokens annotés (toutes entités confondues) ainsi que la répartition par type d’entité : personnes (PER), lieux (LOC) et autres entités (MISC).

On observe tout d’abord que le nombre total de tokens reste stable à 6 500 pour l’ensemble des versions et des textes. Cela suggère une harmonisation préalable des fichiers, probablement dans une phase de prétraitement visant à garantir une comparaison équitable entre les systèmes.

Le nombre de tokens annotés montre cependant des écarts plus marqués. Dans le texte CARRAUD, la version de référence contient 384 tokens annotés, contre 374 pour Kraken et 376 pour Tessfr. Ces différences, bien que modestes, indiquent que les systèmes OCR ont un léger impact sur la capacité à retrouver ou maintenir les entités annotées. Dans le cas de DAUDET, la tendance est similaire, bien que les chiffres globaux soient plus bas : 259

annotations dans la version REF, 260 pour Kraken, et seulement 237 pour Tessfr. Cette diminution pourrait s’expliquer par une moindre densité d’entités nommées dans ce texte ou par une reconnaissance moins performante, notamment dans la version Tessfr.

Les entités de type PER (personnes) constituent de loin la majorité des annotations, avec une très forte présence dans CARRAUD (entre 352 et 358 occurrences) et une moindre représentation dans DAUDET (entre 188 et 202). Ce déséquilibre peut refléter des différences de contenu entre les textes, CARRAUD semblant accorder davantage de place aux personnages nommés.

Les entités LOC (lieux), quant à elles, apparaissent beaucoup plus ponctuellement dans CARRAUD, avec un maximum de 13 occurrences, contre un nombre plus substantiel dans DAUDET, où les trois versions en détectent entre 34 et 38. Cela laisse penser que le second texte contient davantage de toponymes, ou que ceux-ci y sont plus facilement détectables par les systèmes.

Enfin, les entités de type MISC (catégorie fourre-tout regroupant souvent des entités organisationnelles ou autres), bien qu’en nombre réduit, témoignent d’une certaine variabilité d’un système à l’autre. Dans CARRAUD, elles oscillent entre 12 et 15 occurrences, tandis que dans DAUDET, elles varient de 14 à 23. Cette variation peut s’expliquer par des critères d’annotation plus flous pour cette catégorie, ou par une plus grande sensibilité aux erreurs d’OCR.

En somme, si les résultats montrent une relative cohérence entre les différentes versions d’un même texte, ils mettent également en évidence l’influence non négligeable du système de reconnaissance utilisé. Tessfr semble légèrement en retrait, notamment sur le texte DAUDET, tandis que la version Kraken tend à mieux préserver les annotations par rapport à la référence. Ces écarts, bien que modérés, rappellent l’importance d’une OCR de qualité dans tout pipeline de traitement automatique des entités nommées.

Métrique	CARRAUD			DAUDET		
	REF	Kraken	Tessfr	REF	Kraken	Tessfr
Cohen’s Kappa	0.733	0.635	0.603	0.853	0.724	0.755
Fleiss’s Kappa	0.720	0.675	0.587	0.849	0.713	0.741
Krippendorf’s Alpha	0.720	0.675	0.587	0.849	0.713	0.740

TABLE 4.2 – Comparaison des métriques d’accord inter-annotateurs pour CARRAUD et DAUDET, tableau provenant de la thèse de KOUDORO-PARFAIT, 2025

Le tableau 3.1 présente les résultats des métriques d’accord inter-annotateurs

pour deux corpus, CARRAUD et DAUDET, en fonction de la version du texte annoté (texte de référence, version OCR Kraken, version OCR Tessfr). Trois métriques standards sont utilisées pour mesurer la cohérence entre les annotations réalisées manuellement : Cohen’s Kappa, Fleiss’s Kappa et Krippendorff’s Alpha.

De manière générale, les scores les plus élevés sont obtenus pour les textes de référence (REF), qui sont supposés exempts de bruit OCR. Cela indique un haut niveau de cohérence entre annotateurs, et donc une compréhension partagée des entités à annoter dans un contexte textuel clair. Pour le corpus DAUDET, les scores sont particulièrement élevés (jusqu’à 0.853 en Cohen’s Kappa), traduisant une grande fiabilité dans l’annotation, même sur les versions OCR.

L’impact du bruit introduit par les systèmes OCR devient plus apparent dans le cas du corpus CARRAUD, où l’accord entre annotateurs chute de manière significative sur les versions Kraken et Tessfr (jusqu’à 0.587 pour Fleiss’s Kappa et Krippendorff’s Alpha sur Tessfr). Cela suggère que la qualité du texte — altérée par les erreurs de reconnaissance optique — nuit à la capacité des annotateurs à identifier et annoter les entités de manière cohérente, possiblement en raison d’ambiguïtés ou de corruptions lexicales.

Ainsi, ce tableau met en lumière un phénomène crucial : la qualité du texte source a un impact direct sur la qualité des annotations manuelles, et donc, indirectement, sur la constitution de corpus d’apprentissage fiables pour des tâches de reconnaissance d’entités nommées. Il souligne aussi la nécessité de prendre en compte la version du texte dans toute analyse de cohérence inter-annotateurs, notamment dans les corpus issus de documents patrimoniaux soumis à OCR.

	Kraken	REF	Tesseract
Nb de tokens	150074	145109	151974

TABLE 4.3 – Nombre de tokens par version du texte Darien

Dans le tableau ci dessus, vous pouvez retrouver le nombre de token pour chaque version, REF, Kraken et Tesseract, du fichier test que nous avons sélectionné DARIEN dans les 3 versions similaires aux 3 versions de chaque texte que nous avons pour nos fichiers d’entraînement.

Chapitre 5

Préparation des données et entraînement de modèles

5.1 Test du tuto

Nous avons commencé par tester un tutoriel permettant de structurer un modèle de reconnaissance d'entités nommées basé sur SpaCy V3. Nous avons suivi le guide proposé par NewsCatcherAPI¹ NEWS-CATCHER-API, 2024, en appliquant deux variantes d'entraînement : l'une basée sur un transformeur et l'autre sur le modèle tok2vek.

Le tutoriel s'appuie sur un format de données d'entrée en JSON, où chaque annotation est représentée sous une forme précise. Dans la figure suivante, vous pouvez voir ce format de manière détaillée.

```
{
  "id": "18c2f619-f102-452f-ab81-d26f7e283ffe",
  "content": "While bismuth compounds (Pepto-Bismol)
    decreased the number of bowel movements in those
    with travelers' diarrhea...",
  "metadata": {},
  "annotations": [
    {
      "id": "32fdf9e7-63f7-442a-8e25-f08ea4ad94d5",
      "tag_id": "c06bd022-6ded-44a5-8d90-1f7685bb85a1",
      "end": 23,
      "start": 6,
      "example_id": "18c2f619-f102-452f-ab81-d26f7e283ffe",
      "tag_name": "Medicine",
    }
  ]
}
```

1. <https://www.newscatcherapi.com/blog/train-custom-named-entity-recognition-ner-model-with-spacy-v3>


```

    "value": "bismuth compounds",
    "correct": null,
    "human_annotations": [
      {
        "timestamp": "2020-03-21T00:23:46.721000Z",
        "annotator_id": 1,
        "tagged_token_id": "32fdf9e7-63f7-442a-8e25-f08ea4ad94d5",
        "name": "Ashpat123",
        "reason": "exploration"
      }
    ],
    "model_annotations": []
  },
  "classifications": []
}

```

5.2 Détermination de l'accord majoritaire

Dans le cadre de l'adjudication des annotations, nous avons appliqué une série de règles visant à déterminer l'étiquette majoritaire pour chaque token en prenant en compte les corrections effectuées par plusieurs annotateurs, ainsi que les annotations initiales du modèle SpaCy (*Label*). L'objectif est d'obtenir une annotation représentative de la majorité des annotateurs tout en conservant une cohérence avec les décisions prises par le modèle lorsque cela est nécessaire.

5.2.1 Détermination de *Label_Maj* (étiquette majoritaire)

L'étiquette majoritaire est déterminée en analysant les annotations des différents annotateurs dans leur colonne *Correction* tout en tenant compte de l'étiquette initialement attribuée par SpaCy (*Label*). Les règles appliquées pour déterminer l'étiquette majoritaire sont les suivantes :

- **Cas 1** : Si le modèle a attribué une étiquette (*Label*) mais que la majorité des annotateurs (au moins 3) n'ont pas annoté ce token, alors nous conservons l'annotation du modèle dans *Label_Maj*.
- **Cas 2** : Si le modèle a attribué une étiquette mais que la majorité des annotateurs (au moins 3) ont annoté un autre label, alors nous

attribuons à *Label_Maj* l'étiquette majoritaire. Si cette annotation majoritaire est "NA", *Label_Maj* est laissé vide.

- **Cas 3** : En cas d'égalité entre plusieurs annotations des annotateurs, nous conservons l'étiquette du modèle si elle est l'une des annotations majoritaires à égalité.
- **Cas 4** : Si le modèle n'a pas attribué d'étiquette mais qu'une majorité d'annotateurs ont attribué une étiquette, nous choisissons l'étiquette majoritaire. En cas d'égalité entre plusieurs annotations, une étiquette est sélectionnée aléatoirement.

5.2.2 Détermination de *Quaero_Maj* (catégorie fine)

Si l'étiquette majoritaire (*Label_Maj*) est "**LOC**", alors il est impératif d'avoir une annotation dans la colonne *Quaero_Maj*. La détermination de cette annotation suit les règles suivantes :

- **Cas 1** : Une majorité d'annotateurs ont attribué la même étiquette *Quaero*
On conserve cette annotation majoritaire.
- **Cas 2** : Il y a égalité entre plusieurs annotations *Quaero*
On prend une annotation au hasard.
- **Cas 3** : Aucun annotateur n'a mis d'annotation *Quaero*
Ce cas ne devrait pas arriver car *Label_Maj* = "*LOC*" impose qu'il y ait une annotation *Quaero*. Cependant, certains annotateurs n'ont pas respecté cette règle et n'ont pas mis d'annotation *Quaero* lorsqu'ils choisissaient une annotation "*LOC*".

5.2.3 Problèmes rencontrés

- Alignement des annotations : La comparaison entre les annotations automatiques et manuelles s'est avérée difficile en raison du bruit OCR.
- Accord inter-annotateurs : Certaines entités ont été annotées différemment selon les annotateurs, ce qui a nécessité une harmonisation des annotations.
- Impact du bruit OCR : Les erreurs de transcription ont généré des difficultés pour identifier certaines entités, rendant la tâche de REN plus complexe.

5.2.4 Conclusion de cette étape

Ce processus permet d'obtenir une adjudication fiable des annotations en garantissant que :

- Les annotations respectent la majorité des annotateurs.
- L’information du modèle SpaCy est conservée en cas d’égalité.
- Les erreurs d’annotations sont réduites en appliquant un seuil de validation.
- Les tokens liés à des entités *LOC* ont systématiquement une annotation fine (*Quaero_Maj*).

Grâce à ces règles, nous obtenons un fichier consolidé assurant une cohérence entre les annotations des annotateurs et celles du modèle tout en maximisant l’accord inter-annotateurs.

5.3 Formatage des données

5.3.1 Formatage au format JSON

Nous passons ensuite à l’étape de formatage des données, après avoir récupéré les fichiers créés par l’étape du vote majoritaire, nous devons maintenant formater ces données afin qu’elles aient la bonne structure pour être encodées et entraîner les modèles de REN. Le format de données utilisé dans le tutoriel SpaCy² (fichier `Corona2.json`) repose sur une structure riche, adaptée à l’annotation collaborative. Il comporte notamment des champs permettant la traçabilité complète de chaque entité annotée : identifiants, origine de l’annotation (humaine ou automatique), justification, etc.

Pour la création de nos propres fichiers au format JSON à partir de nos données, nous avons produit trois scripts de formatage qui effectuent chacun une mise en forme des données légèrement différentes afin de voir si la façon de formater les données impactera nos modèles et les résultats obtenus, ces scripts produisent des fichiers JSON structurés de manière similaire aux données du tuto dont nous nous inspirons. Nous avons également pris en compte le fait que le formatage de ces données devait être compatible avec un encodage SpaCY par la suite.

Chaque script produits plusieurs fichiers différents à partir des mêmes données d’entrée, un fichier complet contenant toutes les données d’entrées sans distinction d’OCR, 3 fichiers correspondant chacun à un OCR donc un fichier pour REF, un pour Kraken et un pour Tesseract. Et également des fichiers partiels sans distinction des OCR qui correspondent chacun respectivement à 25%, 50% et 75%, ces fichiers ne prennent pas ces pourcentages des données entières, pour chaque fichier le pourcentage est récupérer et ajouter

2. <https://www.newscatcherapi.com/blog/train-custom-named-entity-recognition-ner-model-with-spacy>

au fichier de sortie, cela permettant d'avoir une représentation équivalente de chaque fichier d'entrer de manière proportionnelle et d'éviter la sélection de par exemple la moitié des fichiers lorsque l'on souhaite 50% des données. Tous ces fichiers sont créés pour chaque script d'encodage et identifiés grâce à leurs noms qui représentent le type d'encodage et la version du fichier, afin de créer une sortie compréhensible et organisée.

Les trois scripts ont en commun une structure générale de formatage, où les données sont organisées en documents contenant des séquences de tokens accompagnés de leurs annotations. Toutefois ces scripts diffèrent sur plusieurs points fondamentaux, notamment sur la manière dont les annotations sont insérées dans la structure JSON et sur le niveau de complétude des informations présentes dans les champs.

Dans le premier formatage qui correspondra à notre *Modèle_initial*, les informations sont renseignées de manière minimale. Seuls les tokens sont repris et les entités nommées sont stockées sous forme d'un champ « tags », où seul le nom de la catégorie est indiqué. Les annotations ne sont présentes que dans cette balise et ne sont pas dupliquées dans d'autres champs de la structure, concernant les annotations de type « LOC », les annotations *quaero* sont ajoutées automatiquement avec l'annotation « LOC » et donc incluses automatiquement lorsque cette annotation est présente. Les métadonnées sont réduites à l'essentiel, et aucun identifiant document n'est spécifiquement attribué. Vous pouvez voir dans la figure ci-dessous le formatage utilisé pour ce modèle.

```
{
  "examples": [
    {
      "id": "34296d4e-cfe6-4f26-9aa5-21b11f1437f5",
      "content": "PETITE JEANNE LE DEVOIR ...",
      "metadata": {},
      "annotations": [
        {
          "id": "583cced1-e884-447b-bc5b-710d32f18d8b",
          "tag_id": "08e097ff-a792-48ce-8d55-0a98f0a4cd37",
          "start": 121,
          "end": 132,
          "example_id": "447f0523-226b-4fca-a3f4-fe1e8458425c",
          "tag_name": "LOC, loc.adm.reg",

```

```

        "value": "département",
        "correct": null,
        "human_annotations": [],
        "model_annotations": []
    }
]
}

```

Listing 5.1 – Extrait de notre format utilisé pour l’entraînement du "Modele_initial"

Cette simplification vise à alléger le format et à accélérer le traitement tout en conservant l’essentiel : le texte d’origine et les entités nommées labélisées avec leurs positions. Elle est particulièrement adaptée aux outils comme spaCy qui attendent ce type de structure lors de l’entraînement personnalisé.

Le second formatage que nous utilisons puisque celui enrichi la structure de manière plus détaillée. En plus du champ « tags » contenant les catégories d’entités nommées, chaque token est accompagné d’une information de type qui donne l’annotation manuelle ainsi que l’annotation par le modèle SpaCy dans les espaces attitrés, et l’annotation est également reportée dans un champ « label » associé directement au token. Ce double encodage permet de croiser l’information à plusieurs niveaux de la structure JSON, ce qui facilite certaines formes de traitement en aval. Ce formatage ne contient pas les annotations quæro, qui pourraient de notre avis avoir une fonction discriminante dans l’entraînement du modèle et le REN effectuée après mais nous verrons si cette hypothèse est réelle lors des expériences sur ces sujets. En sommes, ce format a pour particularité de retenir l’étiquette majoritaire dans "name" ainsi que tag_name, mais également de contenir l’annotation de *Spacy* dans "model_annotations", ainsi que toutes les annotations manuelles dans "human_annotations". Vous pouvez voir dans la figure ci-dessous le format JSON exact utilisé pour ce modèle.

```

{
  "id": "adjudication_CARRAUD_petite-Jeanne_TesseractFra-
    PNG_spacy3.7.2-1g",
  "content": "PETITE JEANNE LE DEVOIR ...",
  "metadata": {},
  "annotations": [
    {
      "id": 1,

```

```

        "start_offset": 7,
        "end_offset": 13,
        "tag": {
            "id": 1,
            "name": "PER"
        },
        "tag_name": "PER",
        "model_annotations": [
            "MISC"
        ],
        "human_annotations": [
            "PER",
            "PER",
            "PER",
            "PER",
            "PER"
        ]
    }
]
}

```

Listing 5.2 – Extrait de notre format utilisé pour l’entraînement du "Modele_enrichi"

Le troisième formatage pousse encore plus loin la granularité de l’information. Le format est très similaire au précédent, mais inclut cette fois-ci les annotations *Quaero*. Les étiquettes sont décrites exactement comme le second format, mais cette fois-ci les étiquettes *LOC* sont précisées avec une annotation *Quaero* dans "name" et "tag_name". Elles sont présentes dans ces 2 clés sous le format "*LOC_nom-annotation-quaero*". Cependant, seule l’étiquette *LOC* a été mise en valeur dans *model_annotations* et *human_annotations* pour Voici un aperçu de ce de raisons. Premièrement, *spacy* n’annote pas les entités selon le schéma **Quaero**. Secondement car les annotateurs n’avaient pas tous précisé le label **Quaero** lorsqu’ils annotaient une entité en *LOC*. Vous pouvez voir ci-dessous dans la figure un aperçu du formatage utilisé pour ce dernier modèle.

```

{
  "id": "adjudication_CARRAUD_petite-Jeanne_Kraken-
        base_spacy3.7.2-lg_1_consolide",
  "content": "PTITB JLANN IL DRVOIR ...",
  "metadata": {},
  "annotations": [
    {

```

```

    "id": 51,
    "start_offset": 5218,
    "end_offset": 5222,
    "tag": {
      "id": 2,
      "name": "LOC_loc.adm.reg"
    },
    "tag_name": "LOC_loc.adm.reg",
    "model_annotations": [
      "LOC"
    ],
    "human_annotations": [
      "LOC",
      "LOC"
    ]
  }
]
}

```

Listing 5.3 – Extrait de notre format utilisé pour l’entraînement du "Modèle_enrichi_quaero_fusioné"

Ces différences entre les formatages respectent tout de même une structure logique commune, qui s’appuie sur les annotations fournies dans les fichiers CSV consolidé d’origine sans transformation de contenu mais avec une structuration différente. Ces différentes structures pourront potentiellement influencer l’entraînement au vu des différences dans les métadonnées fournis pour chaque formatage.

5.3.2 Encodage des données au format Spacy

Une fois les fichiers JSON correctement formatés, l’étape suivante consiste à encoder ces données dans un format binaire spécifique à spaCy : le format .spacy. Cette opération est une condition préalable à l’entraînement et à l’évaluation des modèles de reconnaissance d’entités nommées proposés par SpaCy. En effet, ce format permet de stocker efficacement les textes et leurs annotations sous forme d’objets Doc, directement exploitable par les modules internes de SpaCy. Contrairement à un simple fichier texte ou JSON, le format .spacy encapsule les informations linguistiques dans une structure binaire optimisée, ce qui garantit un traitement rapide et une compatibilité totale avec les outils de la bibliothèque.

L’encodage repose sur la classe `DocBin`, qui permet de regrouper plusieurs objets `Doc` dans un conteneur sérialisable. Pour chaque document contenu dans les fichiers JSON, un objet `Doc` est créé à partir du texte brut, puis enrichi avec les entités nommées extraites selon leurs positions dans le texte, normalement délimité par des indices de début et de fin. Dans notre cas, nous avons dû adapter nos différents formatages à cette contrainte. L’alignement des tokens avec l’entité est vérifié et si celui-ci est valide alors l’entité est ajoutée. `SpaCy` impose une correspondance stricte entre les entités et la segmentation tokenisée du texte, toute annotation qui ne respecte pas cette contrainte est donc ignorée pour éviter les erreurs lors de l’entraînement. Une fois que tous les objets `Doc` ont été prétraités, le fichier binaire `.spacy` créé est enregistré.

Trois scripts distincts ont été développés pour cette tâche, correspondant chacun aux différents formatages et donc aux différents formats de fichiers JSON que devait prendre en entrée l’encodage. Bien que le principe de traitement soit donc identique, chaque script adapte sa lecture des champs selon la structure que propose le fichier d’entrée.

Nous avons rencontrés différents problèmes dans la création de cet encodage. Les différents formatages ont été un des premiers challenges puisqu’il a fallu prendre les différences de structure et adapter l’encodage, les règles de `spacy` pour créer ces fichiers très spécifiques sont très strictes, cela a donc demandé beaucoup d’ajustement afin d’éviter le retrait de certaines entités voir de la totalité, nous avons cependant réussi à effectuer cette tâche sans aucune perte.

Ces encodages ont pour finalité de générer des fichiers `.spacy` utilisables dans les différentes étapes expérimentales du projet. Ils servent notamment à l’entraînement de modèles personnalisés via la commande `spacy train`, à l’évaluation de ces modèles à l’aide de `spacy evaluate`, ou encore à la vérification de la cohérence des données avec `spacy debug data`. Grâce à cette conversion, le corpus annoté devient pleinement exploitable par `SpaCy`, ce qui permet de mettre en œuvre des expériences reproductibles et efficaces en reconnaissance d’entités nommées, sur la base de données hétérogènes et potentiellement bruitées.

5.4 Entraînement des modèles

L'entraînement des modèles constitue une étape clé et essentielle du pipeline de reconnaissance d'entités nommées que nous effectuons, permettant de doter les systèmes d'une capacité à détecter automatiquement les entités présentes dans des textes nouveaux. Cette phase repose sur l'utilisation de la bibliothèque spaCy, qui offre une infrastructure robuste pour l'apprentissage supervisé à partir de fichiers de données annotés au format `.spacy`. Chaque version du formatage et tous les différents fichiers générés pour chaque formatage sont utilisés pour entraîner un modèle indépendant, ce qui permet par la suite de comparer leurs performances respectives.

Pour entraîner un modèle spaCy à partir de données personnalisées, il est nécessaire de générer un fichier de configuration `config.cfg`. Ce fichier spécifie l'architecture du modèle, les paramètres d'entraînement, les composants du pipeline (`tok2vec`, `ner`, etc.), ainsi que les chemins vers les jeux de données.

Plutôt que de rédiger ce fichier manuellement, spaCy met à disposition un générateur interactif en ligne à l'adresse suivante :

<https://spacy.io/usage/training#quickstart>

Cet outil permet de créer un fichier `config.cfg` adapté aux besoins spécifiques de l'utilisateur en sélectionnant :

- la tâche souhaitée (par exemple : reconnaissance d'entités nommées),
- la langue et le modèle de base,
- le format d'entrée (JSON, spaCy format, etc.),
- les ressources GPU ou CPU disponibles.

Une fois les paramètres définis, le fichier peut être téléchargé directement et utilisé avec la commande :

```
python -m spacy train config.cfg --output ./output --  
paths.train ./train.spacy --paths.dev ./dev.spacy
```

Concernant les jeux d'entraînement et de développement, nous avons dans un premier temps mis toutes les données dans les deux pour nos premiers tests et par la suite lorsque un modèle s'est distingué des autres nous avons modifié cela en faisant une séparation 80/20 où l'on a utilisé 80% des données pour l'entraînement et 20% pour le test.

Au cours de cette phase, une attention particulière est portée au phénomène de surapprentissage (*overfitting*). Ce dernier survient lorsque le modèle parvient à des scores très élevés sur les données d'entraînement mais est

moins performant sur de nouvelles données. Le surapprentissage est particulièrement visible lorsque'un modèle s'adapte excessivement aux annotations spécifiques d'un annotateur ou à des régularités propres au corpus d'entraînement. Dans notre cas, cela a été observé sur tous nos différents formatage lorsque les jeux d'entraînement et de développement étaient identiques, après on pouvait tout de même remarquer des différences en fonction des données d'entrée, plus le corpus était petit, plus de nombre d'epochs avant que le surapprentissage apparaisse était réduit. Cette manière d'entraîner les données ont pu induire une mémorisation excessive des structures annotées, en comparaison avec notre entraînement 80/20 où on ne peut pas voir ce « comportement ». Pour tenter de limiter ce biais, plusieurs stratégies peuvent être envisagées, comme l'introduction de régularisation, la réduction du nombre d'epochs.

Cette étape d'entraînement, bien qu'encadrée par des paramètres définis en amont, se révèle donc particulièrement sensible aux choix faits en termes de corpus et de configuration. Elle conditionne la qualité des prédictions à venir et constitue un point de bascule critique entre préparation des données et mise en application des modèles.

5.5 REN à partir de nos modèles

Après l'entraînement des différents modèles, ceux-ci sont appliqués à un fichier de test afin d'évaluer leur capacité à identifier les entités nommées dans un contexte nouveau, bien que toujours bruité. Le texte que nous avons choisi provient du même corpus que les 2 textes qui ont servi de données à l'entraînement de nos modèles. "*Le voleur*" écrit par DARIEN a donc servi de test pour nos modèles, et nous avons à nouveau utilisé la version de référence propre du texte, et les 2 versions OCR (Kraken et Tesseract) disponibles sur le dépôt github de ELTeC. Le corpus utilisé est disponible en ligne à l'adresse suivante : github.com/These-SCAI2023/.../DARIEN_Le-voleur. Cette phase, centrée sur la reconnaissance effective, mobilise les modèles enregistrés précédemment pour inférer des annotations sur des documents qui ne faisaient pas partie du jeu d'apprentissage.

L'application des modèles est réalisée grâce à la méthode `pipe()` de spaCy, qui permet un traitement rapide et parallèle des documents. Le modèle chargé analyse chaque fichier test, et prédit pour chaque token s'il correspond à une entité nommée et, le cas échéant, à quelle catégorie celle-ci appartient (PER, LOC, MISc ou ORG). Ces entités détectées sont extraites et stockées dans des

structures réutilisables pour l'évaluation. Les résultats sont ensuite exportés sous forme de fichiers tabulaires ou JSON, organisés selon le modèle utilisé (Modele_initial, Modele_enrichi, Modele_enrichi_quaero_fusionné), le type d'OCR d'origine (REF, Kraken, Tesseract), et le pourcentage d'échantillonnage (25 %, 50 %, 75 %).

L'intérêt majeur de cette étape est d'observer concrètement l'impact de l'entraînement sur la reconnaissance des entités. On y constate notamment les effets du surapprentissage mentionné précédemment : certains modèles, bien qu'efficaces sur les données similaires à leur jeu d'entraînement, peinent à produire des résultats cohérents sur des documents moins familiers, notamment en présence de bruit introduit par les OCR ou d'annotations moins fréquentes. À l'inverse, les modèles entraînés sur des jeux fusionnés, plus variés, montrent une meilleure robustesse, même si leur précision individuelle peut être légèrement inférieure.

Enfin, cette étape prépare le terrain pour l'analyse finale des performances, qui reposera sur la comparaison entre les annotations prédictives et les annotations de référence. En analysant les sorties des modèles sur ces fichiers test, il est possible de dresser un bilan des forces et limites de chaque version entraînée et de mieux comprendre la portée réelle des modèles développés dans le cadre de cette expérimentation.

Chapitre 6

Discussion et résultats

6.1 Comparaison du volume d'entités reconnues

Nous allons commencer notre analyse avec un premier point de vue global. Observons le nombre total d'entités nommées reconnues par les différents modèles (pré-entraînés et personnalisés) sur les trois versions du texte générées par OCR : **Tesseract**, **Kraken** et une version de **référence** nettoyée manuellement. Les résultats sont visualisés dans les graphiques ci-dessous.




FIGURE 6.1 – Nombre total d'entités reconnues par modèle – version REF




FIGURE 6.2 – Nombre total d’entités reconnues par modèle – version Tesseract




FIGURE 6.3 – Nombre total d’entités reconnues par modèle – version Kraken

- L’analyse de ces trois graphiques permet de dégager plusieurs tendances :
- Les modèles pré-entraînés comme **spacy** et **Camembert** détectent un volume important d’entités, avec une surdétection notable sur le texte OCR Kraken (jusqu’à plus de 15 000 entités pour spacy).
 - Le modèle **initial**, peu entraîné, présente une capacité très faible de reconnaissance, ne dépassant jamais 650 entités quelle que soit la

version du texte.

- Les modèles personnalisés **enrichis** montrent de meilleures performances, avec un pic autour de 2 500 entités, en particulier pour la version 80/20 sur le texte de référence.
- Le modèle **enrichi_quaero_fusioné** n’apporte pas d’augmentation significative du volume détecté, ce qui suggère que la fusion d’annotations ne bénéficie pas toujours à la couverture globale.
- Enfin, le texte issu de l’OCR **Kraken** amplifie les quantités détectées par tous les modèles, ce qui reflète une possible surinterprétation du bruit textuel.

Effet du formatage des données d’apprentissage. Une première lecture comparative entre les performances du *Modele_initial* et des variantes *Modele_enrichi* et *Modele_enrichi_quaero_fusioné* montre déjà un effet fort du format de représentation des annotations dans les données d’entraînement. Le *Modele_initial*, construit à partir d’un JSON très simplifié (liste de triplets), reconnaît un volume extrêmement faible d’entités. À l’inverse, les modèles *enrichis*, qui s’appuient sur des annotations plus détaillées dans un format structuré, produisent entre quatre et six fois plus d’entités. Cela indique que la richesse du format d’entrée est essentielle à l’apprentissage, indépendamment du volume des données. En revanche, on observe que la version *enrichi_quaero_fusionné* ne surpasse pas systématiquement la version enrichie classique, ce qui suggère qu’un ajout de données (dans notre cas d’annotations *Quaero* ne produit pas nécessairement un gain immédiat — une hypothèse que nous examinerons plus loin dans l’évaluation fine.

6.2 Répartition des entités nommées par type

Les précédents graphiques ont mis en lumière la capacité globale des différents modèles à détecter des entités nommées, toutes catégories confondues. Afin de mieux comprendre la nature de ces entités, cette section s’attache désormais à étudier leur répartition selon les types d’entités (PER, LOC, ORG, etc.).

Pour chaque moteur OCR (TESSERACT, REF, KRAKEN), nous représentons la répartition des entités reconnues par type et par modèle, sous la forme d’histogrammes empilés. Cette analyse permet d’identifier quels types d’entités sont privilégiés (ou négligés) par les différents systèmes, et de mieux évaluer leur robustesse face à la diversité des annotations.




FIGURE 6.4 – Répartition des entités nommées par modèle (OCR : TESSERACT)

Le graphique 6.4 montre une tendance nette : les modèles entraînés manuellement (notamment `modele_enrichi` et ses variantes) reconnaissent presque exclusivement des entités de type **PER**. Les modèles standards comme `spacy` ou `camembert` offrent une couverture typologique plus large, avec un nombre conséquent d'entités **LOC**, **MISC**, voire **ORG**. En revanche, le modèle `modele_initial` reste très limité, même sur les entités majoritaires.




FIGURE 6.5 – Répartition des entités nommées par modèle (OCR : REF)

Avec la version de référence du texte (figure 6.5), les mêmes tendances se retrouvent. Toutefois, les volumes sont mieux équilibrés : certains modèles (*modele_enrichi_80-20*, *modele_enrichi*) détectent légèrement plus d’entités **LOC**. Néanmoins, seules les solutions standards permettent d’atteindre une diversité typologique significative, avec des entités **LOC** ou **ORG**.




FIGURE 6.6 – Répartition des entités nommées par modèle (OCR : KRAKEN)

Enfin, l’OCR KRAKEN (figure 6.6) confirme la tendance à la spécialisation excessive des modèles entraînés, qui restent presque entièrement centrés sur les entités **PER**. Le bruit textuel de cette version semble également impacter les modèles standards, avec une légère baisse des autres types d’entités reconnues.

Synthèse. Cette analyse met en lumière les limites de généralisation des modèles personnalisés : leur entraînement sur des corpus manuellement annotés, parfois partiels, induit une forte spécialisation sur le type d’entité majoritaire (ici, **PER**). Même les versions enrichies n’apportent qu’un gain limité en diversité. À l’inverse, les modèles standards couvrent plus largement les types d’entités, mais génèrent aussi davantage de bruit. Ces résultats confirment que le choix des données d’entraînement influe fortement sur la capacité des modèles à couvrir l’ensemble des entités pertinentes pour un corpus donné.

6.3 Évaluation des performances :

L’analyse précédente nous a permis d’évaluer le volume et la répartition des entités détectées. Nous allons maintenant nous intéresser à la qualité des entités reconnues, en évaluant la performance de chaque modèle selon les métriques classiques que sont la *précision*, le *rappel* et le *F1-score*, en comparant les entités reconnues par les modèles aux entités de référence produites par spaCy.

- **Évaluation stricte** : une entité est considérée comme correcte uniquement si les indices de début et de fin, ainsi que le type d’entité, correspondent exactement entre la prédiction et la référence.
- **Évaluation tolérante** : une entité est validée si elle partage au moins 50 % de ses caractères avec l’entité de référence (intersection de surface textuelle) et si ses indices de début ou de fin sont proches (écart de ± 5 caractères).

Résultats des évaluations strictes

OCR	Modèle	Précision	Rappel	F1-score	VP	FP
REF	initial	0.4217	0.0671	0.1157	256	351
TESSERACT	initial	0.4448	0.0451	0.0818	250	312
KRAKEN	initial	0.3156	0.0114	0.0221	172	373
REF	enrichi	0.2729	0.1601	0.2020	611	1628
TESSERACT	enrichi	0.2957	0.1195	0.1702	663	1579
KRAKEN	enrichi	0.2208	0.0519	0.0841	781	2756
REF	quaero_fusioné	0.2643	0.1318	0.1759	503	1400
TESSERACT	quaero_fusioné	0.2754	0.0988	0.1454	548	1442
KRAKEN	quaero_fusioné	0.1947	0.0411	0.0679	619	2560
REF	enrichi_80-20	0.2612	0.1698	0.2053	604	2047
TESSERACT	enrichi_80-20	0.2162	0.0975	0.1344	541	1961
KRAKEN	enrichi_80-20	0.1823	0.0410	0.0670	617	2768

TABLE 6.1 – Métriques strictes de performance des modèles (OCR $\times$ modèles)

Interprétation des résultats (évaluation stricte)

Les résultats de l'évaluation stricte, présentés dans le tableau 6.1, permettent de comparer la capacité des différents modèles à identifier précisément les entités nommées en respectant strictement leurs bornes et leur type.

Sans surprise, les modèles **personnalisés enrichis** (`enrichi`, `enrichi_80-20`, `quaero_fusioné`) surpassent le modèle initial, qui peine à dépasser un *F1-score* de 0.12, et ce quel que soit le moteur OCR. Cela confirme que l'ajout d'exemples annotés manuellement est indispensable à l'amélioration des performances.

On remarque également que le moteur **OCR REF** produit globalement de meilleurs scores que KRAKEN ou TESSERACT. Cela s'explique par une qualité textuelle plus propre, offrant des segments mieux reconnus pour l'extraction d'entités.

Les meilleurs résultats sont obtenus par le modèle `enrichi` sur REF ($F1 = 0.2020$) et par `enrichi_80-20` sur REF ($F1 = 0.2053$). Cela suggère qu'une division aléatoire du corpus (80/20) ne pénalise pas significativement les performances.

Le modèle `quaero_fusioné` offre des performances plus équilibrées mais globalement un peu plus faibles, indiquant que l'ajout d'annotations issues d'un autre domaine (Quaero) n'apporte pas forcément un gain substantiel, peut-être en raison de divergences de style ou de distribution des entités.

Enfin, le modèle **initial** affiche une précision relativement correcte (jusqu'à 0.44 sur TESSERACT), mais un *rappel* extrêmement faible. Cela signifie qu'il détecte peu d'entités, mais que celles qu'il reconnaît sont souvent justes, typiquement des entités fréquentes et simples (comme certains noms propres de personne).

Ces résultats mettent en lumière l'intérêt d'une annotation manuelle adaptée au corpus cible, mais aussi l'influence non négligeable de la qualité des textes OCR sur les capacités de reconnaissance.

Résultats des évaluations avec tolérance

OCR	Modèle	Précision	Rappel	F1-score
REF	initial	0.501	0.080	0.137
TESSERACT	initial	0.511	0.052	0.094
KRAKEN	initial	0.383	0.014	0.027
REF	enrichi	0.326	0.191	0.241
TESSERACT	enrichi	0.345	0.140	0.199
KRAKEN	enrichi	0.269	0.063	0.102
REF	quaero_fusioné	0.329	0.164	0.219
KRAKEN	quaero_fusioné	0.249	0.053	0.087
TESSERACT	quaero_fusioné	0.325	0.116	0.171
REF	enrichi_80-20	0.245	0.166	0.198
TESSERACT	enrichi_80-20	0.255	0.115	0.158
KRAKEN	enrichi_80-20	0.225	0.051	0.083

TABLE 6.2 – Scores d'évaluation des modèles personnalisés selon une stratégie de comparaison tolérante (intersection partielle et proximité des indices)

Interprétation des résultats (évaluation tolérante)

L'évaluation tolérante assouplit les critères de correspondance entre les entités reconnues par les modèles et celles de spaCy. Deux entités sont considérées comme équivalentes si elles partagent plus de 50% de leurs caractères et si leur position dans le texte est proche (tolérance de ± 2 caractères). Ce mode de calcul vise à atténuer les erreurs mineures de délimitation d'entités.

Sans surprise, tous les modèles obtiennent de meilleurs *F1-scores* que dans l'évaluation stricte. Le modèle **enrichi** atteint ainsi 0.241 sur REF et 0.191 sur TESSERACT, contre 0.2020 et 0.1702 en évaluation stricte. Cette progression indique que les entités reconnues sont souvent bien localisées, même si leurs bornes exactes ne correspondent pas toujours à celles de spaCy.

L'écart reste néanmoins significatif avec les modèles de référence (spaCy, Camembert), ce qui reflète aussi une différence de stratégie d'annotation : les modèles personnalisés annotent de manière plus sélective, tandis que spaCy a tendance à "sur-analyser" les textes, comme nous le verrons dans les exemples concrets (cf. Tableau 6.3).

L'impact du moteur OCR reste visible : le meilleur score est obtenu sur REF (modèle `enrichi_80-20`, $F1 = 0.198$), alors que KRAKEN reste plus difficile à traiter malgré la tolérance ($F1 = 0.102$ pour le même modèle). Cela confirme une nouvelle fois la sensibilité des modèles aux erreurs introduites par les moteurs de reconnaissance optique de caractères.

Enfin, le modèle `initial` progresse légèrement en précision dans cette évaluation plus souple, mais il reste insuffisant pour des tâches exigeantes. Sa stratégie de détection reste trop pauvre pour une reconnaissance étendue.

En somme, cette évaluation tolérante offre un regard plus nuancé sur les performances réelles : nos modèles sont capables d'identifier approximativement les bonnes entités, mais leur finesse dépend à la fois du format d'entraînement et de la qualité du texte d'entrée.

Exemples concrets d'erreurs

Pour mieux interpréter ces métriques, nous avons examiné plusieurs cas typiques de **faux positifs** (FP) et de **faux négatifs** (FN) sur les sorties du *modèle_enrichi* face au modèle spaCy, sur le texte issu de l'OCR Tesseract.

Texte	Label dèle	mo-	Label spaCy	Commentaire
Georges	PER	-		Vraie entité PER bien détectée par le modèle, ignorée par spaCy
Darien	PER	-		Vraie entité PER bien détectée par le modèle, ignorée par spaCy
La mère Nannette	PER		MISC	Annotation incorrecte de spaCy : MISC au lieu de PER
https ://bit.ly	-		MISC	Faux positif typique de spaCy : une URL détectée à tort comme entité
l’auteur drama- tique	-		PER	Expression générique, peut soulever un questionnement
Jeanne d’Arc	-		PER	Entité importante non détectée par notre modèle
Paris	-		LOC	Lieu correctement détecté par spaCy, manqué par le modèle (absence dans données d’entraînement)
Racine	-		PER	Faux positif de la part de spaCy

TABLE 6.3 – Exemples de faux positifs (première partie) et faux négatifs (deuxième partie) du modèle enrichi sur OCR TESSERACT, vérifiés manuellement

L’analyse qualitative des exemples de faux positifs (FP) et de faux négatifs (FN) met en évidence plusieurs phénomènes notables. Tout d’abord, certaines entités reconnues par notre modèle sont absentes des annotations de spaCy. C’est le cas de *Georges*, *Darien* ou encore *La mère Nannette*, toutes des entités de type PER pertinentes dans le contexte, mais soit ignorées, soit mal catégorisées (comme MISC) par spaCy. Ces erreurs soulignent les limites du modèle spaCy sur des textes anciens ou bruités, notamment OCRisés.

Inversement, spaCy détecte de nombreuses entités qui relèvent du bruit ou d’une généralisation excessive : des URL comme *https ://bit.ly*, des expressions vagues comme *l’auteur dramatique*, ou encore *Racine* dans un contexte où ce nom n’est pas utilisé de manière référentielle. Ces annotations, bien que techniquement valides selon des critères statistiques, manquent de pertinence contextuelle et nuisent à la qualité globale des résultats.

Enfin, certains faux négatifs détectés chez notre modèle peuvent être attribués à une couverture insuffisante des données d’entraînement. C’est le cas de *Jeanne d’Arc* ou *Paris*, entités pourtant bien annotées par spaCy mais absentes des prédictions de notre modèle. Cela montre qu’une meilleure gé-

néralisation du modèle nécessiterait un enrichissement des jeux de données, incluant davantage de variétés lexicales et de contextes historiques.

Ce type d'analyse fine justifie pleinement le recours à une évaluation tolérante, qui permet de reconnaître les cas limites ou partiellement réussis, et de limiter les biais induits par des différences mineures de segmentation ou de label.

Conclusion sur l'évaluation par métriques et par exemples

L'analyse combinée des métriques de performance et des exemples concrets fournit une évaluation complète de la qualité des entités reconnues par les différents modèles. Les métriques strictes soulignent les limitations des modèles dans un cadre d'évaluation rigide, notamment face aux variations de segmentation et de label. Les scores sont globalement faibles, particulièrement en présence de bruit OCR, comme c'est le cas avec KRAKEN ou TESSERACT. L'évaluation tolérante, plus souple, permet de mieux capturer les cas partiellement corrects et révèle ainsi une nette amélioration des performances, en particulier pour les modèles enrichis.

Les modèles personnalisés surpassent systématiquement le modèle initial, tant en précision qu'en rappel, quel que soit le cadre d'évaluation. On observe aussi des écarts significatifs selon le moteur OCR, REF offrant un cadre plus stable et propice à la reconnaissance.

L'analyse qualitative vient nuancer ces résultats chiffrés. Elle montre que notre modèle enrichi est souvent plus pertinent que spaCy, capable de détecter des entités ignorées ou mal catégorisées par ce dernier. Elle révèle également que spaCy tend à sur-analyser certains contenus, en détectant des entités génériques ou bruitées (URLs, noms communs génériques, etc.), ce qui pénalise sa précision. À l'inverse, nos modèles sont plus discriminants, mais parfois trop prudents, échouant à détecter des entités moins fréquentes ou absentes des jeux d'entraînement.

Ces résultats justifient l'intérêt d'une double évaluation : quantitative (via des métriques) et qualitative (via des exemples concrets), indispensable pour interpréter finement les performances des modèles de reconnaissance d'entités nommées dans un contexte de textes anciens et bruités.

6.4 Impact du partitionnement des données d'entraînement

Cette section évalue l'effet de la quantité et du formatage des données d'entraînement sur la capacité des modèles à détecter des entités nommées. Pour chaque modèle (*enrichi*, *enrichi_quaero_fusioné*, *initial*), nous avons varié soit la proportion des données utilisées (25 %, 50 %, 75 %, 100 %), soit restreint l'entraînement à une seule version OCR (REF, KRAKEN, TESSERACT). Les performances sont ensuite observées sur chaque version OCR du texte test (REF, KRAKEN, TESSERACT), en comptant le nombre d'entités reconnues par type.

6.4.1 Modèle *enrichi*




FIGURE 6.7 – Répartition des entités nommées par type sur le texte KRAKEN – Modèle *enrichi*




FIGURE 6.8 – Répartition des entités nommées par type sur les textes REF et TESSERACT – Modèle enrichi

Analyse générale. Contrairement à l'intuition, un volume plus élevé de données d'entraînement n'aboutit pas toujours à une meilleure couverture.

- Sur **KRAKEN**, le modèle entraîné avec seulement 25% des données détecte plus d'entités (4115) que le modèle complet (3537).
- Sur **REF**, 25% permet aussi la meilleure couverture (3181 entités), loin devant les autres partitions.

- Sur **TESSERACT**, le modèle entraîné uniquement sur TESSERACT dépasse nettement tous les autres (2610 entités).

Ces résultats suggèrent qu’une bonne adéquation entre le format des données d’entraînement et celui du texte de test peut être plus décisive que le volume. En outre, une faible quantité de données bien alignées avec la distribution cible semble parfois préférable à un entraînement exhaustif.

Effet du formatage. En testant sur une version donnée (par exemple, TESSERACT), le modèle le plus performant est souvent celui entraîné exclusivement sur la même version OCR (TESSERACT *vs* TESSERACT = 2610). Ce constat se vérifie également pour KRAKEN (TESSERACT > complet) ou REF (25% > complet).

Par type d’entité. Les entités *PER* sont majoritaires dans tous les cas. Mais :

- Le modèle entraîné sur REF donne plus de *MISC* (385 sur TESSERACT) que sur REF lui-même (381), illustrant une certaine instabilité inter-corpus.
- Le modèle entraîné sur KRAKEN produit de nombreuses *LOC* (645 sur KRAKEN), alors qu’elles sont rares pour d’autres modèles.

6.4.2 Comparaison avec les autres modèles

Les figures associées pour les modèles *initial* et *enrichi_quaero_fusioné* sont disponibles en annexe (cf. figure .1.1, figure .1.2).

Modèle initial. Celui-ci montre une dynamique similaire, mais avec des volumes plus faibles. Par exemple, il détecte moins de 600 entités sur REF avec les modèles complets ou restreints. Cela reflète une couverture plus limitée, et surtout une plus grande fragilité aux données bruitées (très faible performance sur KRAKEN).

Modèle enrichi quaero fusioné. Il présente des comportements plus variables. On note que :

- Le modèle entraîné uniquement sur KRAKEN donne le meilleur score sur REF (940), ce qui est atypique.
- La performance du modèle complet est correcte mais inférieure à certaines partitions.

Conclusion. L'analyse suggère que :

- La quantité de données n'est pas un facteur linéairement bénéfique.
- L'adéquation entre le format des données d'entraînement et du test est essentielle.
- Les résultats sont plus stables pour le modèle enrichi que pour le modèle fusionné ou initial.

Une analyse qualitative complémentaire serait nécessaire pour évaluer la justesse des entités produites.

6.5 Analyse des longueurs et de la similarité des entités

6.5.1 Analyse des longueurs des entités

Objectif. Il s'agit ici de comparer la longueur moyenne des entités reconnues par nos modèles à celles reconnues par spaCy, sur les trois versions OCR du texte. L'objectif est de vérifier si les modèles formés à partir de nos données produisent des entités plus courtes, plus longues ou comparables à celles d'un modèle pré-entraîné de référence.




FIGURE 6.9 – Différence moyenne de longueur (en caractères) entre les entités reconnues par nos modèles et celles de spaCy. Une valeur négative signifie que le modèle produit des entités plus courtes.

Interprétation. Tous les modèles produisent en moyenne des entités plus courtes que spaCy, ce qui confirme les tendances qualitatives observées précédemment : spaCy a tendance soit à sur-annoter, soit à englober plus d'informations dans ses entités. Nous avons pu observer plus tôt le cas de *Mr.*

Randal annoté entièrement par spaCy, alors que nos modèles ont tendances à annoter uniquement *Randal*. Nous pouvons formuler l'hypothèse que cette différence d'annotation réside dans le fait que nos modèles sont entraînés sur des données bruitées, et qu'ils pourraient donc avoir tendance à prendre le . pour du bruit à ne pas prendre en compte.

On observe toutefois quelques variations dans la manière d'annoter entre nos différents modèles :

- Le *Modele_initial* produit les entités les plus courtes sur REF et TESSERACT, ce qui reflète sa faible couverture globale et des annotations souvent tronquées.
- Le *Modele_enrichi_80-20* se distingue par des différences particulièrement fortes sur KRAKEN, ce qui indique qu'il produit des entités souvent partielles ou plus resserrées que celles de spaCy.
- Le *Modele_enrichi_quaero_fusioné*, bien que performant, reste le plus proche des longueurs de spaCy : sa différence moyenne est la plus faible sur REF et TESSERACT.

Il est à noter que cette analyse est purement quantitative et ne préjuge pas de la qualité réelle des entités détectées. La longueur seule ne permet pas de conclure à la justesse des annotations.

6.5.2 Analyse de la similarité des entités

Cette section a pour objectif d'évaluer la proximité textuelle entre les entités reconnues par nos modèles et celles de spaCy. Deux approches distinctes ont été explorées : l'une reposant sur l'alignement des entités dans le texte (position), et l'autre ignorant leur position, en comparant toutes les entités globalement.

A. Similarité positionnelle : Jaccard vs Levenshtein




FIGURE 6.10 – Comparaison des similarités textuelles moyennes calculées à partir de l’intersection des entités par position : Jaccard (en bleu) et Levenshtein (en orange).

Méthodologie. Seules les entités dont la position dans le texte est proche (tolérance de quelques caractères) ont été conservées. On calcule alors, pour chaque paire d’entités :

- **Jaccard** : Intersection sur les caractères partagés / union des caractères totaux.
- **Levenshtein** : Distance d’édition normalisée entre les chaînes de caractères.

Interprétation.

- Le score Jaccard est plus exigeant que Levenshtein : la moindre différence dans la chaîne impacte fortement la similarité.
- Tous les modèles personnalisés obtiennent de meilleures similarités que le modèle initial, ce qui reflète un alignement plus fin avec les entités de référence.
- Les versions enrichies (avec Quaero ou 80-20) améliorent très légèrement les scores, en particulier en Levenshtein, ce qui suggère une meilleure proximité orthographique.

B. Similarité globale des entités reconnues

Nous comparons ici l’ensemble des entités reconnues (quelle que soit leur position) avec celles de spaCy, via deux mesures : Levenshtein et Cosine. Les

entités ont été vectorisées (ngrams caractères pour Cosine).




FIGURE 6.11 – Similarité moyenne (Cosine et Levenshtein) entre les entités reconnues par nos modèles et celles de spaCy, pour chaque OCR.




FIGURE 6.12 – Distribution des similarités globales (Cosine à gauche, Levenshtein à droite) selon les modèles, tous OCR confondus.

Interprétation.

- Les modèles *enrichis* atteignent les similarités globales les plus élevées, quel que soit le type de métrique.
- Le score Cosine est toujours supérieur au score Levenshtein : il est plus tolérant aux petites variations internes.
- Le modèle *enrichi_80-20* atteint parfois des scores équivalents voire meilleurs que le modèle complet : le formatage plus homogène semble avoir un effet positif.
- La qualité est généralement meilleure pour les textes *REF*, et diminue nettement pour *TESSERACT* et *KRAKEN*, ce qui est cohérent avec

le degré de bruit textuel.

Les figures supplémentaires sont présentées en annexe pour le détail par OCR et par métrique : cf. figure 7.

Chapitre 7

Conclusion générale

Ce mémoire a exploré la reconnaissance d’entités nommées (REN) dans un contexte particulièrement bruité : celui de textes issus d’OCR (reconnaissance optique de caractères), avec pour objectif d’entraîner, d’évaluer et d’améliorer les performances de modèles entraînés spécifiquement sur ces données.

Nous avons comparé plusieurs modèles : un modèle initial, un modèle enrichi (incluant davantage de données annotées), et un modèle fusionné avec Quaero. Nos analyses ont porté à la fois sur des métriques classiques (précision, rappel, F1-score), sur la nature et la longueur des entités reconnues, et sur des mesures de similarité textuelle entre les entités détectées par nos modèles et celles du modèle de référence spaCy.

Les résultats montrent que les modèles personnalisés, en particulier le modèle enrichi, surpassent spaCy en termes de précision et de capacité à produire des entités plus discriminantes. Les annotations de spaCy, bien que plus longues, sont souvent bruitées ou mal segmentées, tandis que nos modèles ont appris à être plus sélectifs. L’évaluation tolérante confirme cette tendance en atténuant l’effet de divergences minimales de surface. Les modèles personnalisés ont donc une tendance à mieux annoter, mais à être peut-être un peu trop discriminants.

L’étude de l’impact du partitionnement des données d’entraînement révèle que plus de données n’entraîne pas nécessairement une meilleure couverture. Des sous-ensembles bien choisis (par exemple, entraînement uniquement sur les textes issus de Tesseract) peuvent s’avérer plus efficaces lorsqu’on applique le modèle sur des textes de même type. Cela met en lumière l’importance de l’adéquation entre les données d’entraînement et les données cibles.

Enfin, l’analyse de la longueur et de la similarité des entités détectées confirme que nos modèles produisent des unités plus compactes, mais parfois moins proches lexicalement des entités de spaCy. Cela reflète des stratégies d’annotation différentes, probablement influencées par la nature même des

textes d’entraînement.

Limites. Ce travail repose en partie sur des annotations de référence elles-mêmes imparfaites (issues de spaCy), et les évaluations ont été menées à l’aide de métriques principalement quantitatives. Certaines annotations considérées comme “faux positifs” ou “faux négatifs” selon les métriques apparaissent en réalité correctes ou erronées lors d’une vérification humaine. Une étude d’évaluation manuelle plus systématique serait nécessaire pour affiner ces résultats.

Perspectives. Plusieurs prolongements sont envisageables. D’une part, l’exploration de modèles plus récents (comme des transformers adaptés au bruit OCR) pourrait améliorer la robustesse. D’autre part, l’intégration de règles linguistiques ou d’informations contextuelles (comme la position dans la phrase ou la typographie) pourrait permettre de mieux désambigüiser certaines entités. Enfin, une généralisation sur d’autres corpus OCR (avec d’autres types de textes ou d’autres langues) permettrait de confirmer la transférabilité des modèles entraînés.

Ce mémoire illustre donc l’intérêt d’un entraînement sur mesure, adapté au domaine et à la qualité des données, pour améliorer la reconnaissance d’entités nommées dans des contextes difficiles comme les textes OCRisés.

Annexes

.1 Résultats détaillés du partitionnement des données d'entraînement pour les autres modèles

.1.1 Modèle initial




FIGURE 1 – Répartition des entités par type – OCR KRAKEN – Modèle initial




FIGURE 2 – Répartition des entités par type – OCR REF – Modèle initial




FIGURE 3 – Répartition des entités par type – OCR TESSERACT – Modèle initial

.1.2 Modèle enrichi quaero fusioné




FIGURE 4 – Répartition des entités par type – OCR KRAKEN – Modèle enrichi quaero fusioné




FIGURE 5 – Répartition des entités par type – OCR REF – Modèle enrichi quaero fusioné




FIGURE 6 – Répartition des entités par type – OCR TESSERACT – Modèle enrichi quaero fusioné

.2 Précisions des mesures de similarité




FIGURE 7 – Figures supplémentaires : similarité moyenne par OCR ou par modèle (Cosine et Levenshtein)

.3 Retrouver tous nos codes et fichiers sur Github

Voici le lien vers notre Github où sont disponibles tous les codes et fichiers utilisés et/ou créés pour ce mémoire organisés en suivant l'ordre des différentes étapes réalisées et évoquées dans ce mémoire.

Notre Github

Bibliographie

- AI, C., JIANG, Y., HUANG, S., XIE, P., & TU, K. (2024). Learning Robust Named Entity Recognizers From Noisy Data With Retrieval Augmentation. *arXiv preprint arXiv :2407.18562*. <https://arxiv.org/abs/2407.18562>
- BELTAGY, I., LO, K., & COHAN, A. (2019). SciBERT : A Pretrained Language Model for Scientific Text. *EMNLP*. <https://aclanthology.org/D19-1371>
- DERCZYNSKI, L., NICHOLS, E., van ERP, M., & LIMSOPATHAM, N. (2017). Results of the WNUT2017 shared task on novel and emerging entity recognition. *Proceedings of the 3rd Workshop on Noisy User-generated Text*, 140-147. <https://aclanthology.org/W17-4418>
- DEVLIN, J., CHANG, M.-W., LEE, K., & TOUTANOVA, K. (2019). BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding. *arXiv preprint arXiv :1810.04805*. <https://arxiv.org/abs/1810.04805>
- ELTEC, P. (2020). European Literary Text Collection (ELTeC). <https://www.distant-reading.net/eltec/>
- HAMDI, A., LINHARES PONTES, E., SIDÈRE, N., COUSTATY, M., & DOUCET, A. (2022). In-Depth Analysis of the Impact of OCR Errors on Named Entity Recognition and Linking. *arXiv preprint*. <https://hal.archives-ouvertes.fr/hal-03615997>
- KOUDORO-PARFAIT, C. (2025). Des IA au service de l'espace littéraire du XIXe siècle : évaluation et analyse des outils de reconnaissance d'entités nommées spatiales. (2025SORUL012). <https://theses.hal.science/tel-05042915>
- KOUDORO-PARFAIT, C., LEJEUNE, G., & BUTH, R. (2022). Reconnaissance d'entités nommées sur des sorties OCR bruitées : des pistes pour la désambiguïsation morphologique automatique. In Y. ESTÈVE, T. JIMÉNEZ, T. PARCOLLET & M. ZANON BOITO (Éd.), *Actes de la 29e Conférence sur le Traitement Automatique des Langues Natu-*

- relles. *Atelier TAL et Humanités Numériques (TAL-HN)* (p. 45-55). ATALA. <https://hal.science/hal-03701476>
- KOUDORO-PARFAIT, C., LEJEUNE, G., & ROE, G. (2021). Spatial Named Entity Recognition in Literary Texts : What is the Influence of OCR Noise? *Proceedings of the 5th ACM SIGSPATIAL Workshop on Geospatial Humanities*. <https://doi.org/10.1145/3486187.3490206>
- LAMPLE, G., BALLESTEROS, M., SUBRAMANIAN, S., KAWAKAMI, K., & DYER, C. (2016). Neural architectures for named entity recognition. *Proceedings of NAACL-HLT*. <https://aclanthology.org/N16-1030>
- MARTIN, L., MULLER, B., et al. (2020). CamemBERT : A Tasty French Language Model. *ACL 2020*. <https://aclanthology.org/2020.acl-main.645>
- MAYHEW, S., CHATURVEDI, S., TSAI, C.-T., & ROTH, D. (2019). Named Entity Recognition with Partially Annotated Training Data. *Proceedings of the 23rd Conference on Computational Natural Language Learning (CoNLL)*, 645-655. <https://doi.org/10.18653/v1/K19-1060>
- MERDJANOVSKA, E., AYNETDINOV, A., & AKBİK, A. (2024, novembre). NoiseBench : Benchmarking the Impact of Real Label Noise on Named Entity Recognition. In Y. AL-ONAIZAN, M. BANSAL & Y.-N. CHEN (Éd.), *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing* (p. 18182-18198). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2024.emnlp-main.1011>
- MIKOLOV, T., CHEN, K., CORRADO, G., & DEAN, J. (2013). Efficient Estimation of Word Representations in Vector Space. *Proceedings of the International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/1301.3781>
- MONCLA, L., & ZEGHIDI, H. (2025). Token and Span Classification for Entity Recognition in French Historical Encyclopedias. *arXiv preprint arXiv :2506.02872*. <https://arxiv.org/abs/2506.02872>
- NEWSCATCHERAPI. (2024). Tutoriel sur l'entraînement d'un modèle NER avec SpaCy V3. <https://www.newscatcherapi.com/blog/train-custom-named-entity-recognition-ner-model-with-spacy-v3>
- NGUYEN, T. T. H., JATOWT, A., COUSTATY, M., & DOUCET, A. (2021). Survey of Post-OCR Processing Approaches. *ACM Computing Surveys*, 54(6), 1-37. <https://doi.org/10.1145/3453476>
- PETERS, M. E., NEUMANN, M., IYYER, M., GARDNER, M., CLARK, C., LEE, K., & ZETTLEMOYER, L. (2018). Deep contextualized word representations. *Proceedings of NAACL-HLT*. <https://arxiv.org/abs/1802.05365>

- PETKOVIC, L., KOUDORO-PARFAIT, C., DESMAREST, M.-S., & LEJEUNE, G. (2025). Quelle solution pour améliorer les performances de la reconnaissance d’entités nommées sur des données bruitées, corriger l’entrée ou filtrer la sortie ? *Corpus*, 26. <https://journals.openedition.org/corpus/9059>
- RIJHWANI, S., & NEUBIG, G. (2020). OCR Post-Correction for Under-Resourced Languages Using Zero-Shot Transfer and Multilingual Language Modeling. *Proceedings of EMNLP 2020*. <https://aclanthology.org/2020.emnlp-main.478/>
- TJONG KIM SANG, E. F., & DE MEULDER, F. (2003). Introduction to the CoNLL-2003 Shared Task : Language-Independent Named Entity Recognition. *Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL 2003*, 142-147. <https://aclanthology.org/W03-0419>
- WEISCHEDEL, R., PRADHAN, S., RAMSHAW, L., XUE, N., PALMER, M., MARCUS, M., & et AL. (2013). OntoNotes Release 5.0. *LDC2013T19, Linguistic Data Consortium, Philadelphia, PA*. <https://catalog.ldc.upenn.edu/LDC2013T19>